INSTITUT TEKNOLOGI DEL

MATERI PRAKTIKUM

4233201 – Kecerdasan Buatan

Semester Ganjil Tahun Ajaran 2026/2027

Session Date	**:** 14 Oktober 2026
Week/Session	**:** 6/3
Topic	**:** Text Classification
Practicum Goals	**:** Mahasiswa mampu melakukan semua tahap dalam proses klasterisasi teks
Duration	**:** 2 x 50 minutes
Place of Submission	**:** ecourse
Submission Deadline	**:** Akhir Sesi

Untuk pemahaman yang lebih mendalam mengenai clustering teks, silakan merujuk pada sumber berikut:

Klik di sini

Sumber ini menyajikan pembahasan komprehensif mengenai teknik, algoritma, serta penerapan clustering dalam analisis teks.

In [1]:
```
# Import library
import pandas as pd
import numpy as np
import re
import string
from nltk.tokenize import word_tokenize
from nltk.stem import WordNetLemmatizer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
```

In [2]:
```
# Load dataset
file_path = "Text.csv"
df = pd.read_csv(file_path)

# Hanya mengambil kolom message untuk klasterisasi
df = df.rename(columns={'Message': 'text'})
```

In [3]:
```
# Inisialisasi lemmatizer
lemmatizer = WordNetLemmatizer()

# Fungsi preprocessing teks
def clean_text(text):
    text = text.lower()  # Lowercasing
    text = re.sub(r'\d+', '', text)  # Hapus angka
    text = text.translate(str.maketrans('', '', string.punctuation))  # Hapus tanda baca
    words = word_tokenize(text)  # Tokenisasi
    words = [lemmatizer.lemmatize(word) for word in words]  # Lemmatization
    return ' '.join(words)

# Terapkan preprocessing ke teks
df['clean_text'] = df['text'].apply(clean_text)

# Konversi teks ke vektor TF-IDF
vectorizer = TfidfVectorizer(stop_words='english')  # Menggunakan stopwords dari sklearn
X = vectorizer.fit_transform(df['clean_text'])

# Tentukan jumlah klaster
num_clusters = 2
kmeans = KMeans(n_clusters=num_clusters, random_state=42, n_init=10)
df['cluster'] = kmeans.fit_predict(X)

# Visualisasi dengan PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X.toarray())

plt.figure(figsize=(8, 6))
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=df['cluster'], cmap='viridis', alpha=0.7)
plt.xlabel("PCA Component 1")
plt.ylabel("PCA Component 2")
plt.title("Text Clustering dengan K-Means")
```

```
plt.colorbar(label='Cluster')
plt.show()
```

