PRAKTIKUM UTS KECERDASAN BUATAN

Nama : Oktova Yoga Praditia Samosir
NIM : 42324002 (NIM Genap)
Prodi : D3 Teknologi Informasi
Mata Kuliah : Kecerdasan Buatan
Tahun Ajaran : Semester Gasal T.A. 2025/2026

Panduan Pengerjaan:

Notebook ini berisi jawaban praktikum UTS Kecerdasan Buatan yang disusun secara terstruktur per langkah pengerjaan (*step-by-step*), meliputi:

- **Soal 1**: Eksplorasi Data pada dataset `users_data_cleaned.pickle` (13 langkah eksplorasi)
- **Soal 2**: Regresi Linear pada dataset `Sales_Data.csv` (Prediksi Nilai Penjualan berdasarkan Biaya Promo)
- **Soal 3**: Klasterisasi K-Means pada dataset `konsumen.csv` (Khusus NIM Genap)

Setiap langkah pengerjaan dipisahkan dalam sel kode tersendiri dan disertai penjelasan terpisah untuk menerangkan logika kode serta interpretasi hasil outputnya.

Soal 1: Eksplorasi Data `users_data_cleaned.pickle`

1. Load and preview the data

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

path = "users_data_cleaned.pickle"
df = pd.read_pickle(path)
df.head()
```

Out[1]:

	user_id	number_transactions	total_amount_usd	age	job	marital	educ
0	9231c446-cb16-4b2b-a7f7-ddfc8b25aaf6	3.0	2143.0	58	management	married	te
1	bb92765a-08de-4963-b432-496524b39157	NaN	NaN	44	technician	single	seco
2	573de577-49ef-42b9-83da-d3cfb817b5c1	2.0	2.0	33	entrepreneur	married	seco
3	d6b66b9d-7c8f-4257-a682-e136f640b7e3	NaN	NaN	47	blue-collar	married	
4	fade0b20-7594-4d9a-84cd-c02f79b1b526	1.0	1.0	33	None	single	

Penjelasan:

Pada langkah pertama ini, kita mengimpor pustaka (*library*) utama yang dibutuhkan untuk pengolahan data dan visualisasi, yaitu `pandas`, `numpy`, `matplotlib.pyplot`, dan `seaborn`. File dataset `users_data_cleaned.pickle` dimuat ke dalam DataFrame pandas dengan fungsi `pd.read_pickle()`. Kemudian fungsi `head()` digunakan untuk menampilkan 5 baris pertama data agar kita dapat melihat sekilas struktur tabel dan fitur-fitur yang ada, seperti `age`, `job`, `marital`, `education`, `number_transactions`, dan `total_amount_usd`.

2. Check the shape of the data

In [2]:
```
print("Jumlah baris dan kolom:", df.shape)
```

```
Jumlah baris dan kolom: (45209, 19)
```

Penjelasan:

Perintah `df.shape` digunakan untuk melihat dimensi ukuran dataset. Dari output terlihat `(45209, 19)`, yang artinya dataset ini memiliki 45.209 baris data pelanggan dan 19 kolom variabel/fitur.

3. Check the data types

In [3]:
```
df.dtypes
```

Out[3]:
```
user_id                       object
number_transactions          float64
total_amount_usd             float64
age                            int64
job                           object
marital                       object
education                     object
default                         bool
housing                         bool
loan                            bool
contact                       object
duration                       int64
campaign                       int64
pdays                          int64
previous                       int64
poutcome                      object
term_deposit                    bool
date_joined          datetime64[ns]
device                        object
dtype: object
```

Penjelasan:

Fungsi `df.dtypes` digunakan untuk memeriksa tipe data pada setiap kolom. Terlihat bahwa terdapat kolom bertipe numerik integer (`int64`), bilangan pecahan (`float64`), dan tipe teks/kategori (`object`). Pengecekan tipe data ini sangat penting agar kita tahu kolom mana yang siap diproses secara matematis dan kolom mana yang merupakan data kategorikal.

4. Check for correlations

In [4]:
```
df.corr(numeric_only=True)
```

Out[4]:

	number_transactions	total_amount_usd	age	default	housin
number_transactions	1.000000	-0.163409	-0.008813	0.138838	0.03042
total_amount_usd	-0.163409	1.000000	0.095839	-0.065390	-0.06685
age	-0.008813	0.095839	1.000000	-0.017875	-0.18555
default	0.138838	-0.065390	-0.017875	1.000000	-0.00602
housing	0.030429	-0.066857	-0.185552	-0.006020	1.00000
loan	0.075319	-0.084526	-0.015641	0.077232	0.04134
duration	-0.017220	0.022586	-0.004645	-0.010017	0.00504
campaign	0.026431	-0.017274	0.004767	0.016819	-0.02358
pdays	-0.030751	0.006435	-0.023745	-0.029982	0.12419
previous	-0.023046	0.016952	0.001297	-0.018331	0.03708
term_deposit	-0.053390	0.050785	0.025168	-0.022421	-0.13916

Penjelasan:

Fungsi `df.corr(numeric_only=True)` menghitung matriks korelasi Pearson antar variabel numerik. Nilai koefisien korelasi bergerak di antara -1 hingga +1. Nilai mendekati 1 menandakan korelasi linier positif yang kuat, nilai mendekati -1 menandakan korelasi negatif yang kuat, sedangkan nilai mendekati 0 menandakan tidak adanya hubungan linier yang signifikan antar variabel.

5. Generate summary statistics for numerical data only

In [5]:
```
df.select_dtypes(include='number').describe()
```

Out[5]:

	number_transactions	total_amount_usd	age	duration	campaign
count	35210.000000	35210.000000	45209.000000	45209.000000	45209.000000
mean	3.977052	1369.417751	40.935853	258.153067	2.763897
std	3.814329	3063.412688	10.618653	257.525446	3.098076
min	1.000000	-8019.000000	18.000000	0.000000	1.000000
25%	2.000000	73.000000	33.000000	103.000000	1.000000
50%	3.000000	451.000000	39.000000	180.000000	2.000000
75%	4.000000	1438.000000	48.000000	319.000000	3.000000
max	20.000000	102127.000000	95.000000	4918.000000	63.000000

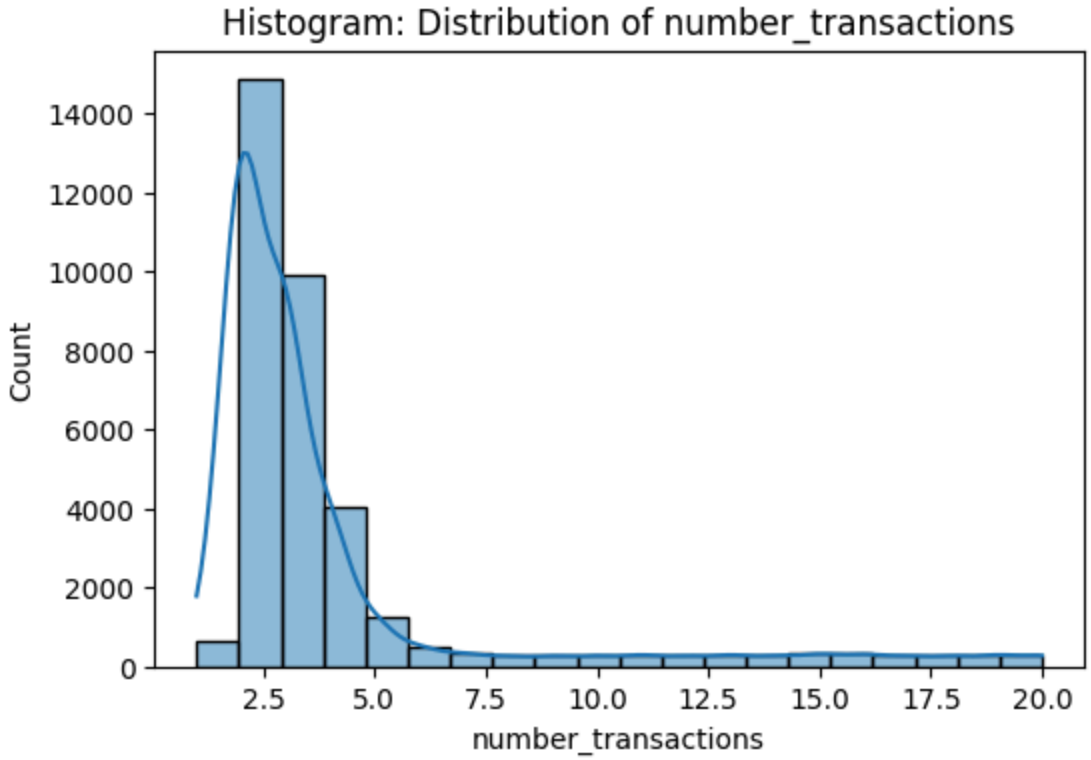
Penjelasan:

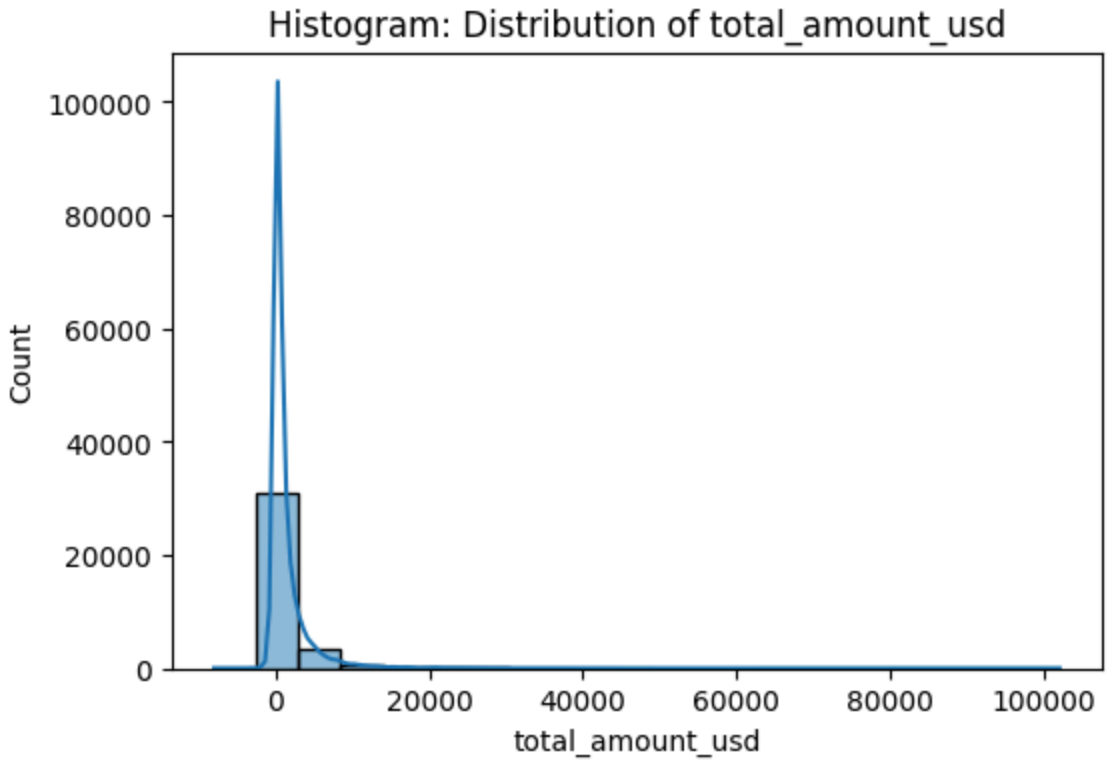
Fungsi `select_dtypes(include='number').describe()` menghasilkan statistik deskriptif khusus untuk seluruh variabel numerik. Informasi yang disajikan mencakup jumlah data (`count`), nilai rata-rata (`mean`), simpangan baku (`std`), nilai minimum (`min`), kuartil bawah 25% (Q1), median/kuartil tengah 50% (Q2), kuartil atas 75% (Q3), dan nilai maksimum (`max`). Dari tabel ini kita dapat mengamati rentang nilai dan mendeteksi sebaran data pengguna.

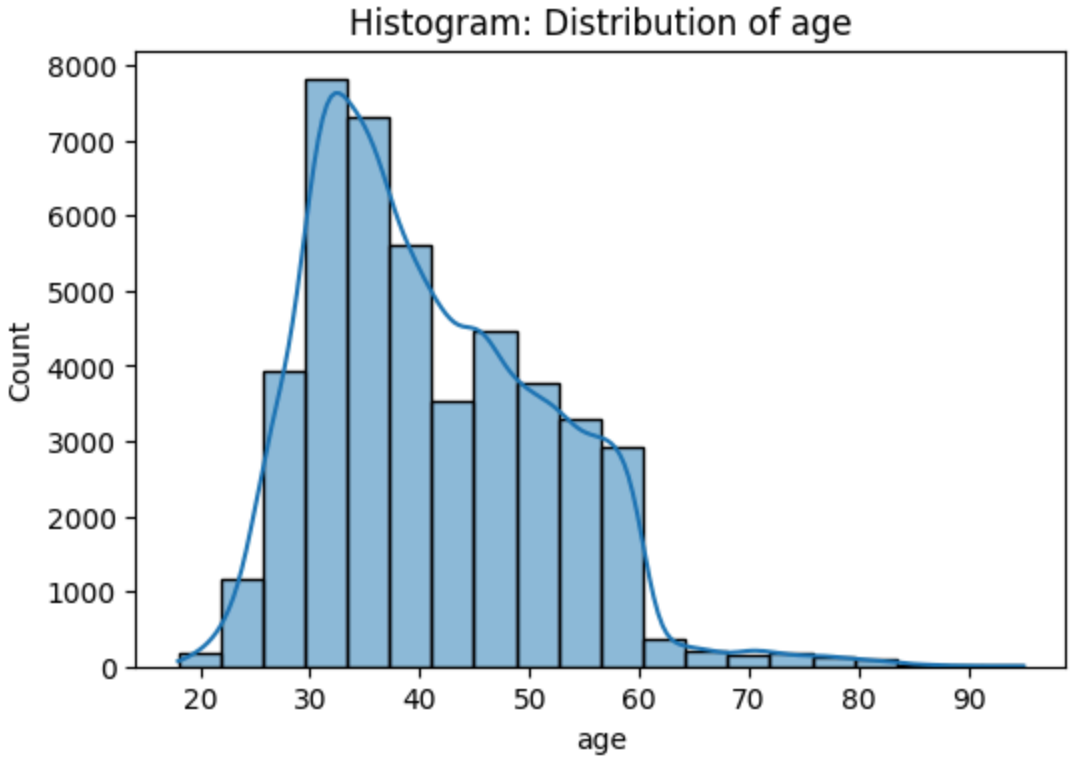
6. Plot Histograms for all numerical columns

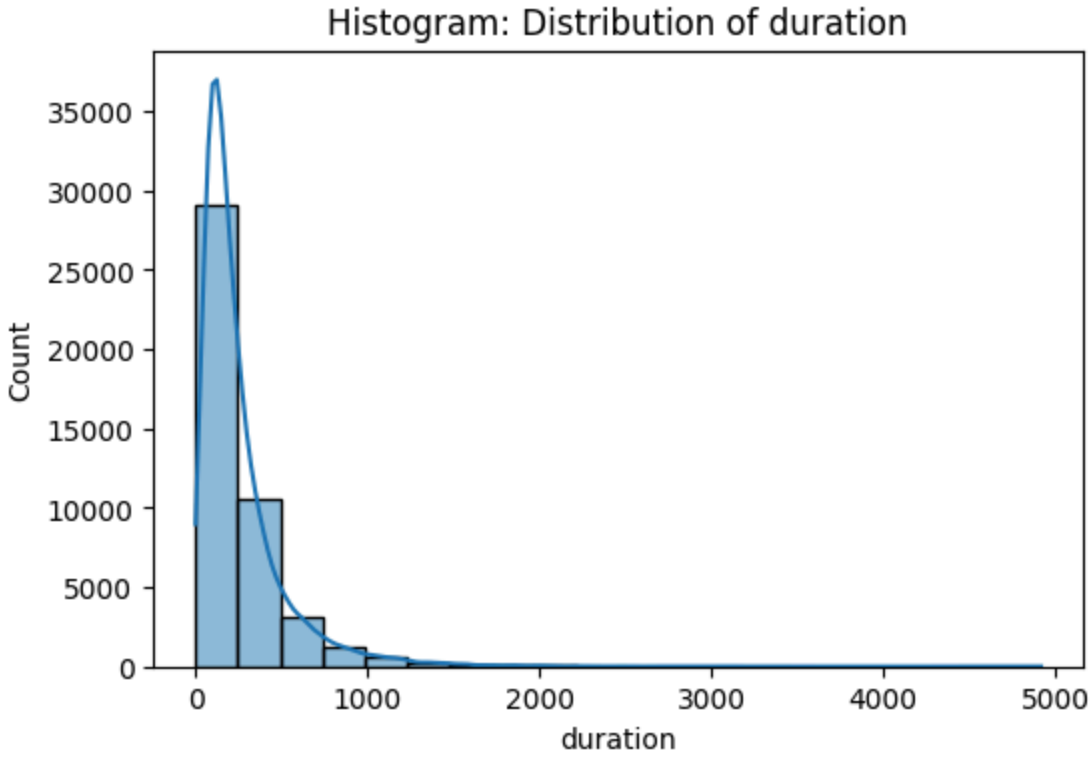
In [6]:
```
numeric_cols = df.select_dtypes(include='number').columns

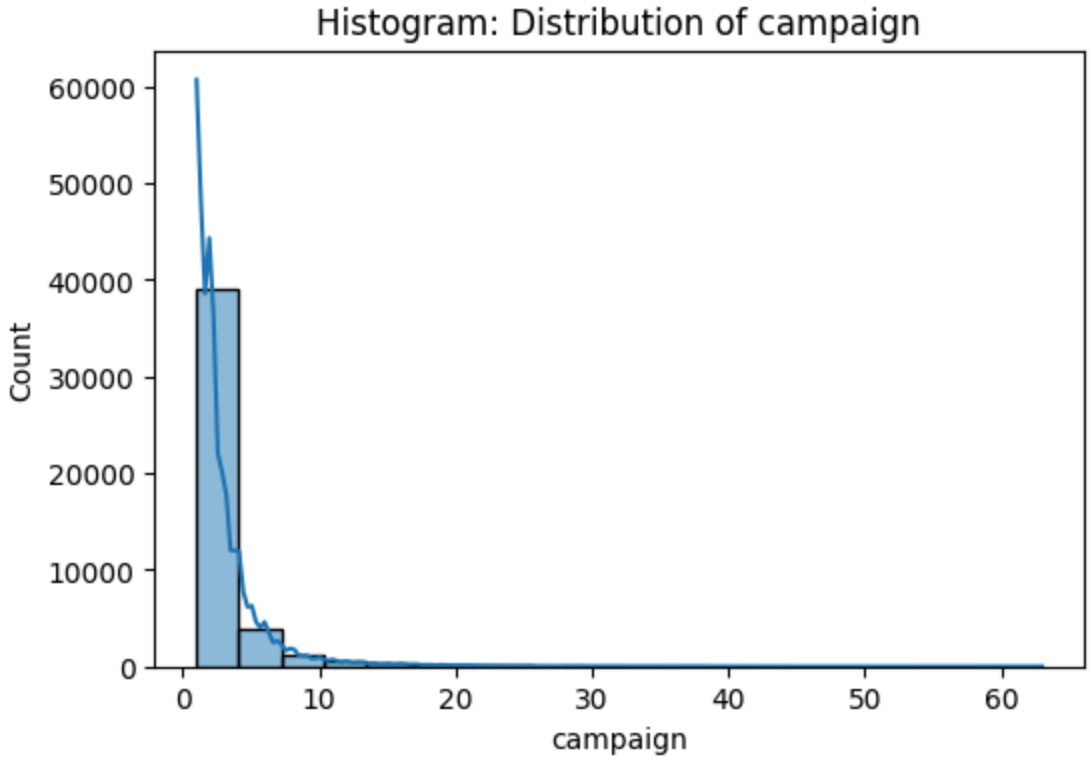
for col in numeric_cols:
    plt.figure(figsize=(6,4))
    sns.histplot(df[col], bins=20, kde=True)
    plt.title(f"Histogram: Distribution of {col}")
    plt.show()
```

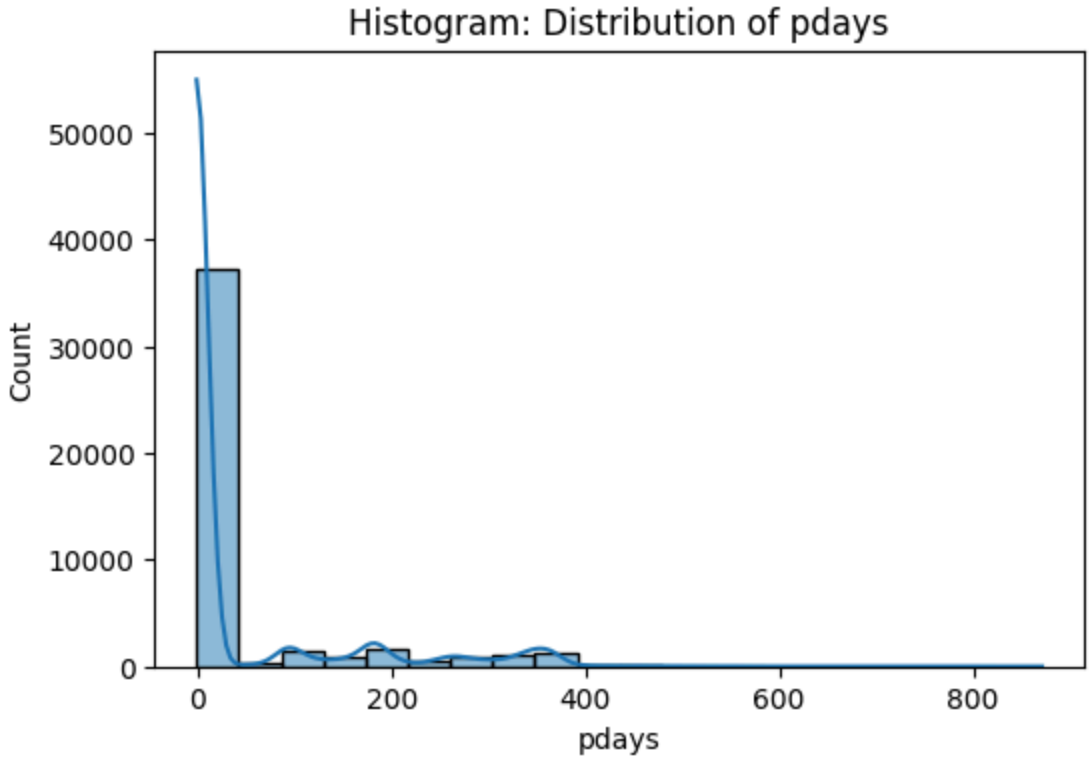

Histogram: Distribution of number_transactions
Count
number_transactions
0
2000
4000
6000
8000
10000
12000
14000
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0

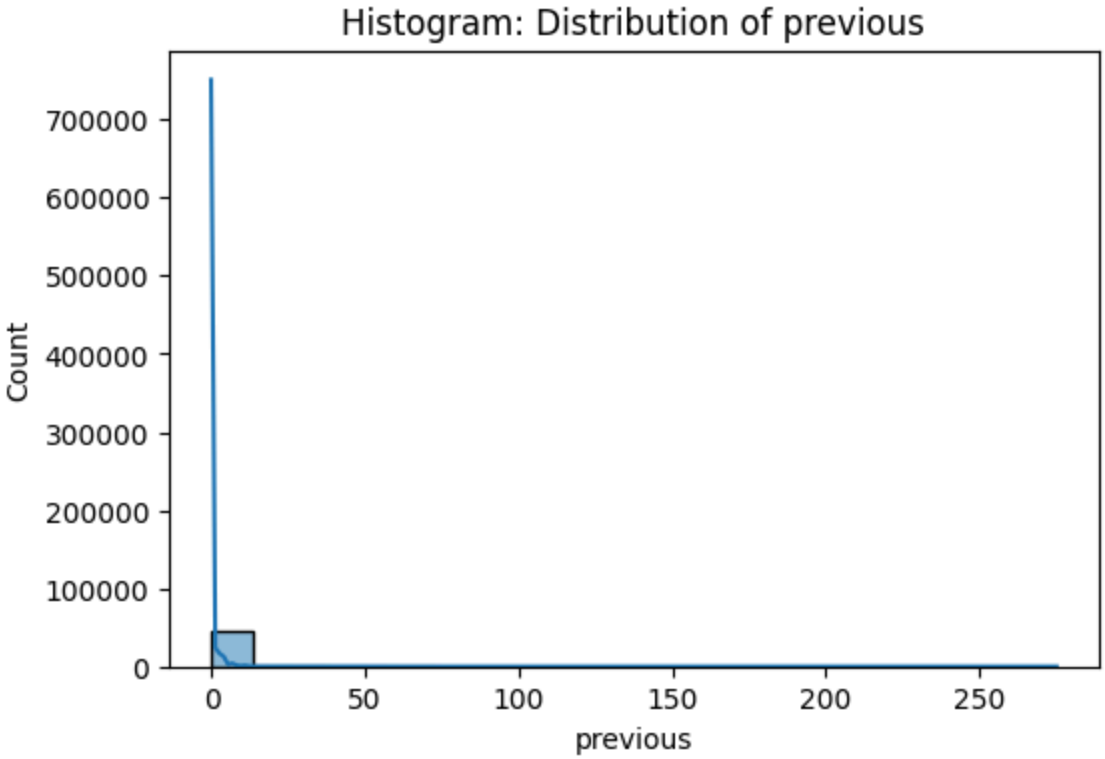

Histogram: Distribution of total_amount_usd
Count
total_amount_usd
0
20000
40000
60000
80000
100000


Histogram: Distribution of age
Count
age
0
1000
2000
3000
4000
5000
6000
7000
8000
20
30
40
50
60
70
80
90


Histogram: Distribution of duration
Count
duration
0
5000
10000
15000
20000
25000
30000
35000
0
1000
2000
3000
4000
5000


Histogram: Distribution of campaign
Count
campaign
0
10000
20000
30000
40000
50000
60000
0
10
20
30
40
50
60


Histogram: Distribution of pdays
Count
pdays
0
10000
20000
30000
40000
50000
0
200
400
600
800



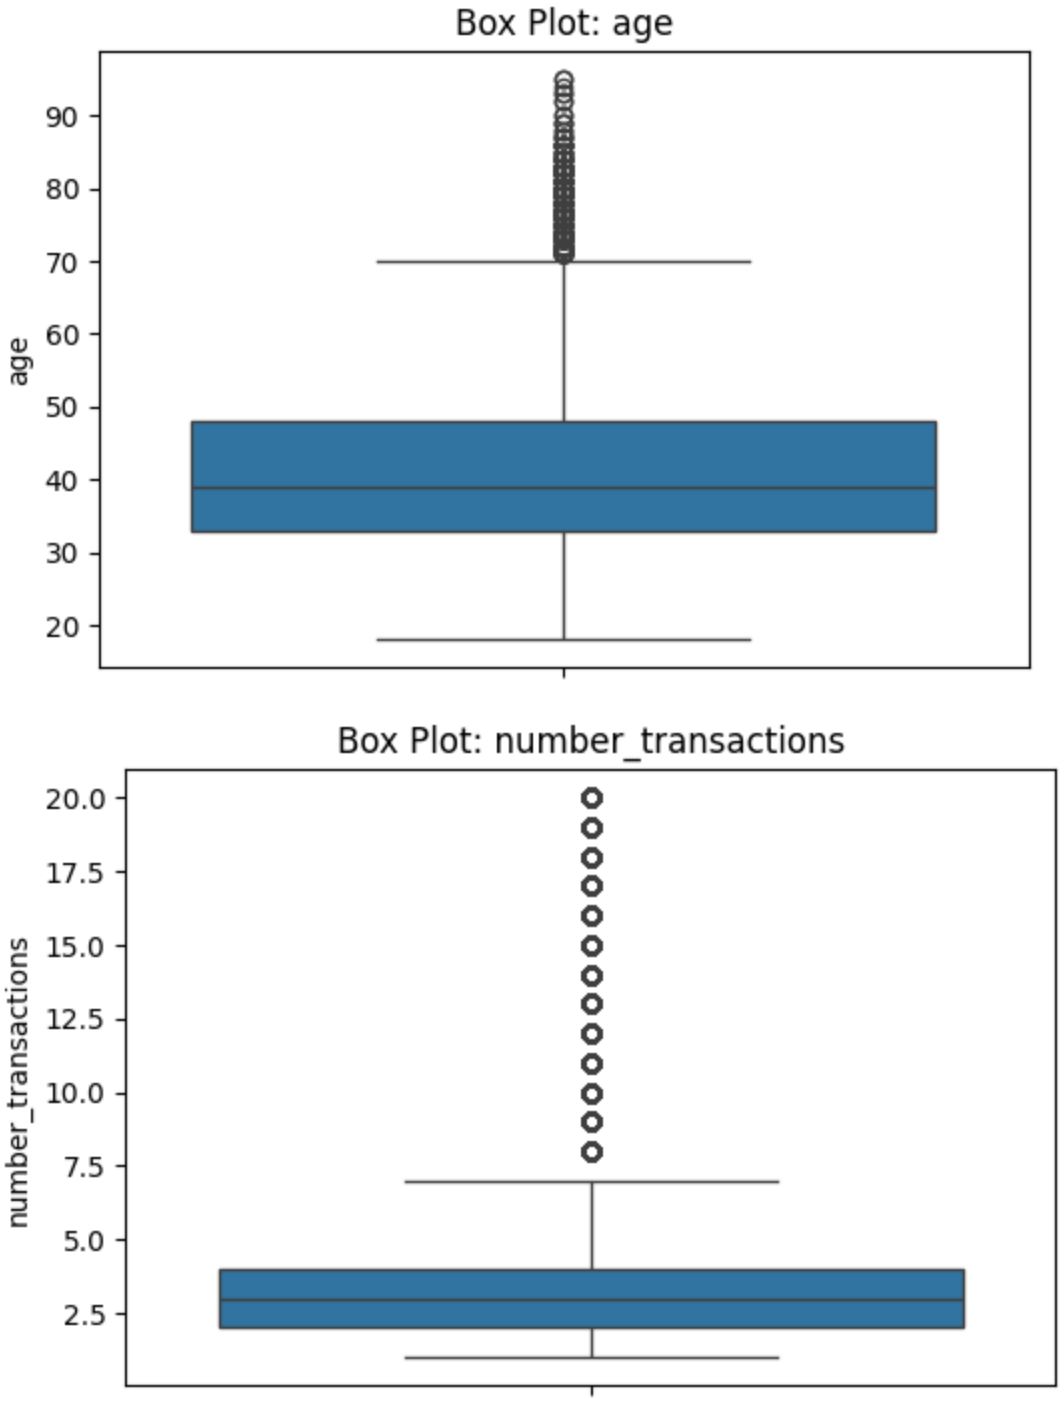
Penjelasan:

Kode di atas melakukan perulangan untuk memplot histogram pada setiap kolom numerik, disertai dengan kurva KDE (*Kernel Density Estimation*). Histogram ini berfungsi untuk melihat bentuk distribusi frekuensi masing-masing variabel, apakah condong (*skewed*) ke kanan/kiri atau simetris menyerupai distribusi normal.

7. Generate a box plot for *age* and *number_transactions*

In [7]:
```
plt.figure(figsize=(6,4))
sns.boxplot(y=df['age'])
plt.title("Box Plot: age")
plt.show()

plt.figure(figsize=(6,4))
sns.boxplot(y=df['number_transactions'])
plt.title("Box Plot: number_transactions")
plt.show()
```



Penjelasan:

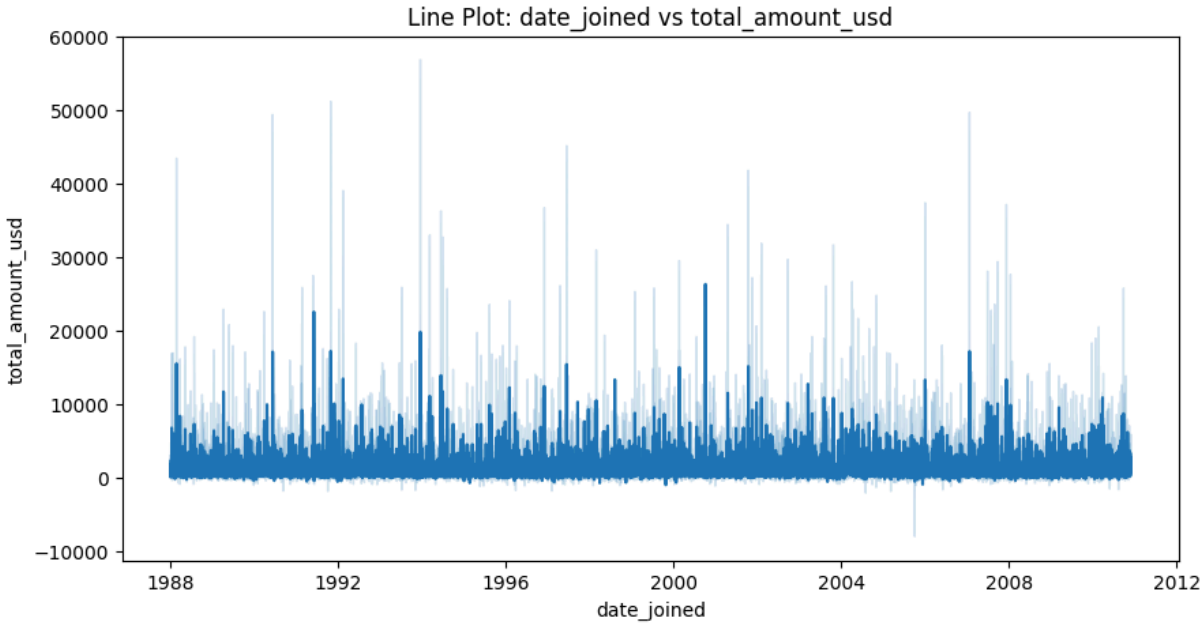
Box plot digunakan untuk memvisualisasikan sebaran data berdasarkan kuartil sekaligus mengidentifikasi titik pencilan (*outlier*).

- Pada variabel `age`, mayoritas usia pengguna berkisar antara 30 hingga 50 tahun, dengan beberapa titik outlier pada rentang usia lanjut (> 70 tahun).
- Pada variabel `number_transactions`, terlihat banyak titik outlier di atas batas atas (*upper whisker*), yang menunjukkan ada sebagian kecil pelanggan dengan frekuensi transaksi yang sangat tinggi dibanding pengguna kebanyakan.

8. Generate a lineplot for *date_joined* to *total_amount_usd*

In [8]:
```
df_sorted = df.sort_values('date_joined')

plt.figure(figsize=(10,5))
sns.lineplot(x='date_joined', y='total_amount_usd', data=df_sorted)
plt.title("Line Plot: date_joined vs total_amount_usd")
plt.xlabel("date_joined")
plt.ylabel("total_amount_usd")
plt.show()
```

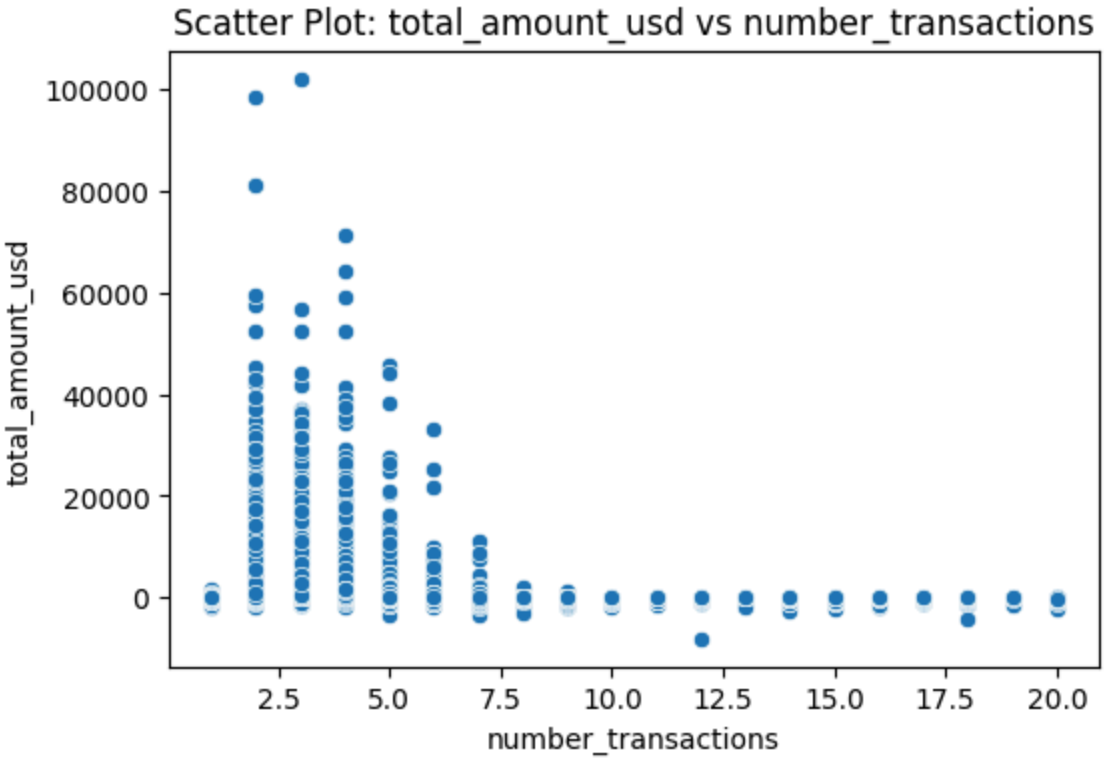


Penjelasan:

Data terlebih dahulu diurutkan berdasarkan tanggal bergabung (`date_joined`) menggunakan `sort_values()` , lalu dibuat grafik garis (*line plot*) untuk melihat pergerakan nilai transaksi pengguna (`total_amount_usd`) seiring berjalannya waktu pendaftaran.

9. Generate scatter plots comparing *total_amount_usd* to *number_transaction*

In [9]:
```
plt.figure(figsize=(6,4))
sns.scatterplot(x='number_transactions', y='total_amount_usd', data=df)
plt.title("Scatter Plot: total_amount_usd vs number_transactions")
plt.show()
```

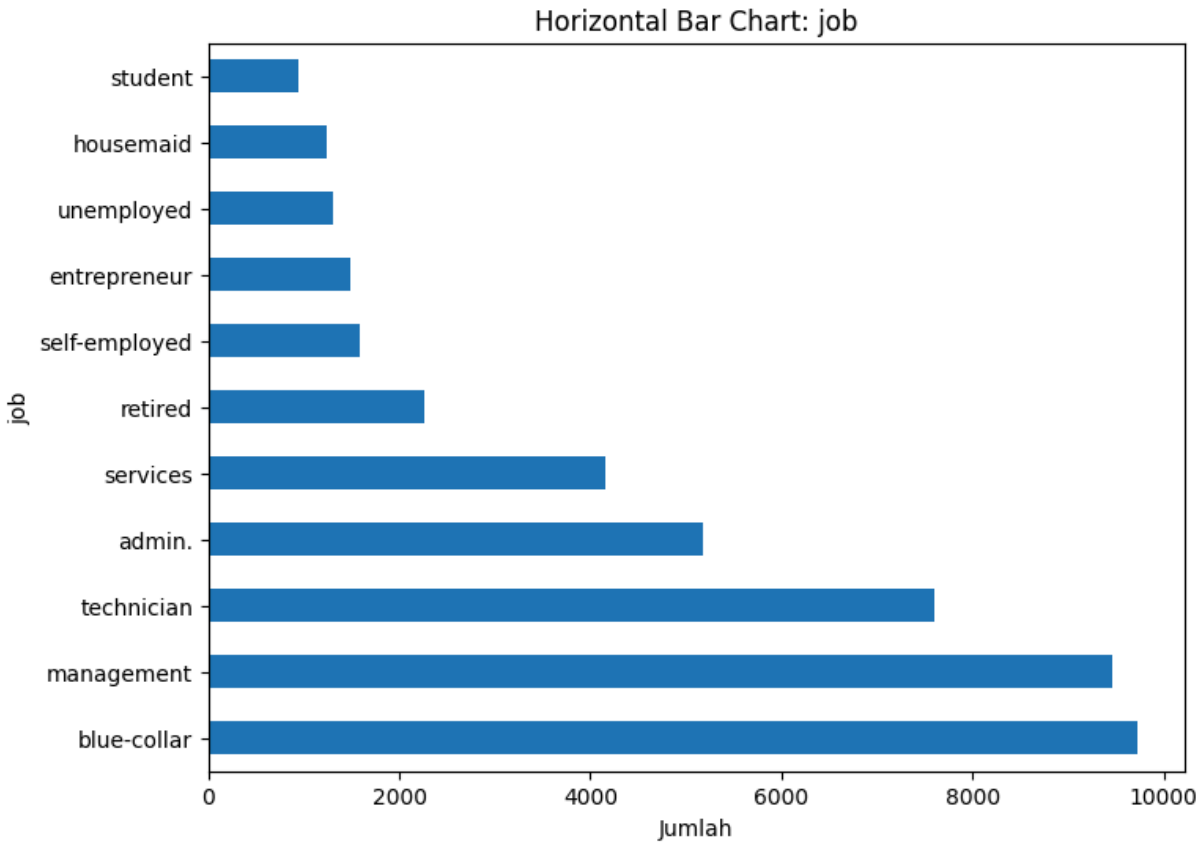


Penjelasan:

Scatter plot ini memetakan korelasi antara jumlah transaksi (`number_transactions` pada sumbu X) dan total uang yang dibelanjakan (`total_amount_usd` pada sumbu Y). Terlihat pola tren positif yang cukup jelas di mana semakin banyak transaksi yang dilakukan pengguna, maka total nominal belanjaannya pun cenderung semakin besar.

10. Generate Horizontal bar charts for *job*

In [10]:
```
plt.figure(figsize=(8,6))
df['job'].value_counts().plot(kind='barh')
plt.title("Horizontal Bar Chart: job")
plt.xlabel("Jumlah")
plt.ylabel("job")
plt.show()
```

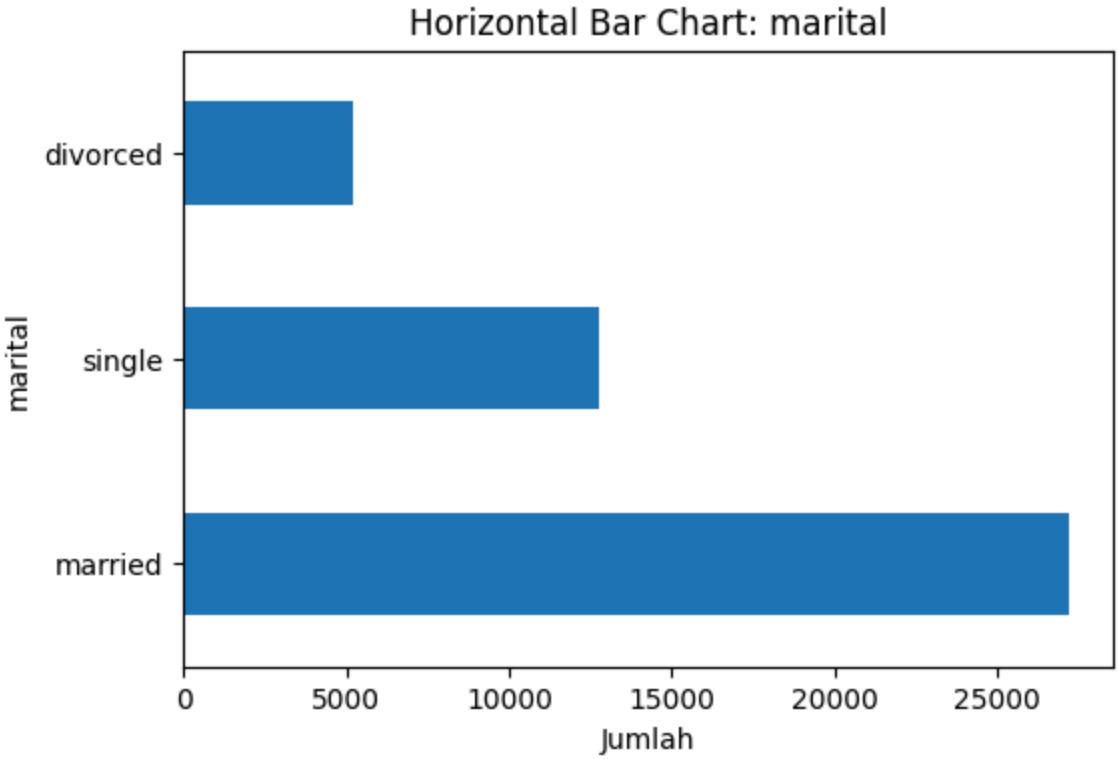


Penjelasan:

Fungsi `value_counts()` menghitung frekuensi setiap jenis profesi pelanggan pada kolom `job`, lalu divisualisasikan dalam diagram batang horizontal (`barh`). Dari grafik terlihat jenis pekerjaan yang mendominasi pelanggan antara lain pekerja kerah biru (*blue-collar*), manajemen, dan teknisi.

11. Generate Horizontal bar charts for *marital*

In [11]:
```
plt.figure(figsize=(6,4))
df['marital'].value_counts().plot(kind='barh')
plt.title("Horizontal Bar Chart: marital")
plt.xlabel("Jumlah")
plt.ylabel("marital")
plt.show()
```

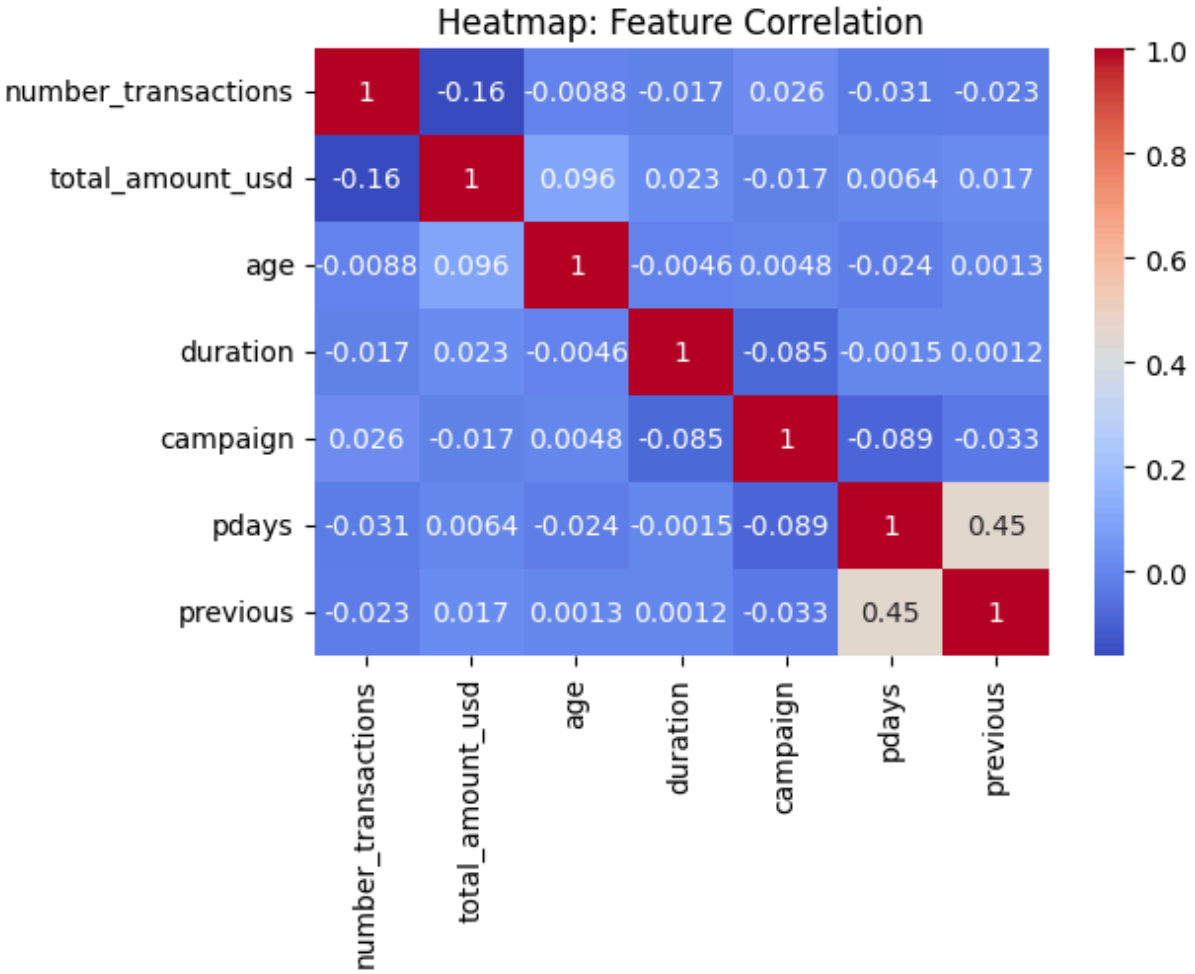


Penjelasan:

Diagram batang horizontal ini menampilkan sebaran status perkawinan (`marital`) pelanggan. Dari visualisasi terlihat mayoritas pelanggan sudah menikah (*married*), disusul pelanggan yang belum menikah (*single*), dan yang bercerai (*divorced*).

12. Generate a heatmap for feature correlations

In [12]:
```
plt.figure(figsize=(6,4))
sns.heatmap(df.select_dtypes(include='number').corr(), annot=True, cmap='coolwarm')
plt.title("Heatmap: Feature Correlation")
plt.show()
```



Penjelasan:

Heatmap korelasi ini memvisualisasikan kekuatan hubungan antar variabel numerik menggunakan warna. Parameter `annot=True` menampilkan nilai numerik koefisien korelasi di setiap kotak, dan colormap `coolwarm` memudahkan kita membedakan hubungan positif (nuansa hangat/merah) dan hubungan negatif (nuansa dingin/biru).

13. Identify Missing Values

In [13]:
```
df.isnull().sum()
```

Out[13]:
```
user_id                  0
number_transactions     9999
total_amount_usd        9999
age                        0
job                      288
marital                    0
education               1857
default                    0
housing                    0
loan                       0
contact                13018
duration                   0
campaign                   0
pdays                      0
previous                   0
poutcome               36957
term_deposit               0
date_joined               30
device                    94
dtype: int64
```

Penjelasan:

Perintah `df.isnull().sum()` memeriksa dan menjumlahkan seluruh data kosong (*missing value*) pada masing-masing kolom. Output ini memberikan gambaran langsung kolom mana saja yang memiliki nilai kosong dalam dataset.

In [14]:
```
percent_missing = 100*df.isnull().mean()
percent_missing
```

Out[14]:
```
user_id                 0.000000
number_transactions    22.117278
total_amount_usd       22.117278
age                     0.000000
job                     0.637041
marital                 0.000000
education               4.107589
default                 0.000000
housing                 0.000000
loan                    0.000000
contact                28.795151
duration                0.000000
campaign                0.000000
pdays                   0.000000
previous                0.000000
poutcome               81.746997
term_deposit            0.000000
date_joined             0.066358
device                  0.207923
dtype: float64
```

Penjelasan:

Menghitung persentase nilai kosong untuk setiap kolom dengan membagi jumlah missing value terhadap total baris dan dikalikan 100%. Informasi persentase ini penting untuk menentukan apakah data kosong tersebut perlu diimputasi (diisi) atau dihapus jika persentasenya terlalu besar.

Soal 2: Linear Regression `Sales_Data.csv`

Memprediksi **Nilai Penjualan** dari **Biaya Promo**.

1.a Membaca file Sales_Data.csv

In [15]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv('Sales_Data.csv', sep=';')
print(df.head())
```

```
   BiayaPromo  NilaiPenjualan
0        1500           90500
1        1800           89500
2        1900          105000
3        2050          102000
4        2050           90500
```

Penjelasan:

Dataset `Sales_Data.csv` dibaca menggunakan fungsi `pd.read_csv()` dengan parameter `sep=';'` karena separator data pada file CSV tersebut menggunakan titik koma. Fungsi `df.head()` menampilkan 5 baris pertama yang memuat data biaya promosi dan nilai penjualan.

1.b Menampilkan variable dalam dataset

Kolom `BiayaPromo` = X (predictor), kolom `NilaiPenjualan` = y (target).

In [16]:
```
print("Nama kolom:", list(df.columns))

X = df.iloc[:, :-1].values
y = df.iloc[:, 1].values

print("Variabel X (Biaya Promo), 5 data pertama:\n", X[:5])
print("Variabel y (Nilai Penjualan), 5 data pertama:\n", y[:5])
```

```
Nama kolom: ['BiayaPromo', 'NilaiPenjualan']
Variabel X (Biaya Promo), 5 data pertama:
 [[1500]
 [1800]
 [1900]
 [2050]
 [2050]]
Variabel y (Nilai Penjualan), 5 data pertama:
 [ 90500  89500 105000 102000  90500]
```

Penjelasan:

Pada tahap ini, kita memisahkan kolom ke dalam dua variabel:

- **Variabel X (Fitur Prediktor)**: Diambil dari kolom pertama (`BiayaPromo`) menggunakan `.iloc[:, :-1].values` .
- **Variabel y (Target)**: Diambil dari kolom kedua (`NilaiPenjualan`) menggunakan `.iloc[:, 1].values` . Keduanya dikonversi menjadi array numpy agar siap diproses oleh algoritma regresi dari pustaka scikit-learn.

1.c Menampilkan data yang di-split (train: 80% & test: 20%)

In [17]:
```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_sta

print("X_train:\n", X_train)
print("y_train:\n", y_train)
print("X_test:\n", X_test)
print("y_test:\n", y_test)
print("Jumlah data train:", len(X_train), "| Jumlah data test:", len(X_test))
```

```
X_train:
 [[3200]
 [4000]
 [2200]
 [3750]
 [2050]
 [1900]
 [2100]
 [3750]
 [3200]
 [2400]
 [4000]
 [3500]
 [2050]
 [1500]
 [3900]
 [3500]]
y_train:
 [153000 170500 109500 198000  90500 105000 104500 187000 173000 150000
 200500 174500 102000  90500 194500 150000]
X_test:
 [[4100]
 [1800]
 [4500]
 [3050]]
y_test:
 [204500  89500 224500 152000]
Jumlah data train: 16 | Jumlah data test: 4
```

Penjelasan:

Fungsi `train_test_split` dari `sklearn.model_selection` membagi dataset menjadi dua bagian: 80% sebagai data latih (*training set*) untuk melatih model regresi, dan 20% sebagai data uji (*testing set*) untuk menguji performa model. Parameter `random_state=0` digunakan agar pembagian data selalu sama (konsisten) saat dijalankan ulang. Dari total 20 sampel data, 16 sampel digunakan untuk train dan 4 sampel untuk test.

1.d Memanggil LinearRegression()

In [18]:
```
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

Out[18]:

▾ LinearRegression ⓘ ?

▸ Parameters

Penjelasan:

Pada langkah ini, kita mengimpor kelas `LinearRegression` dari `sklearn.linear_model`, menginisialisasi objek model `regressor`, lalu melatih model pada data latih menggunakan perintah `regressor.fit(X_train, y_train)`. Model akan mencari garis lurus terbaik (*best fit line*) yang meminimalkan jumlah kuadrat selisih antara data aktual dan garis prediksi.

1.e Menampilkan hasil predict dari data test

In [19]:
```
y_pred = regressor.predict(X_test)
y_pred
```

Out[19]:
```
array([197842.1437866 ,  97374.89156365, 215314.70939059, 151976.65907612])
```

Penjelasan:

Fungsi `regressor.predict(X_test)` menghasilkan nilai estimasi penjualan berdasarkan nilai biaya promosi pada data uji. Hasil prediksi `y_pred` adalah array nilai penjualan yang diestimasikan oleh model machine learning.

1.f Menampilkan Grafik Nilai Penjualan berdasarkan Biaya Promosi

In [20]:
```
plt.scatter(X, y, color='red')
plt.title('Nilai Penjualan berdasarkan Biaya Promo')
plt.xlabel('Biaya Promo')
plt.ylabel('Nilai Penjualan')
plt.show()
```

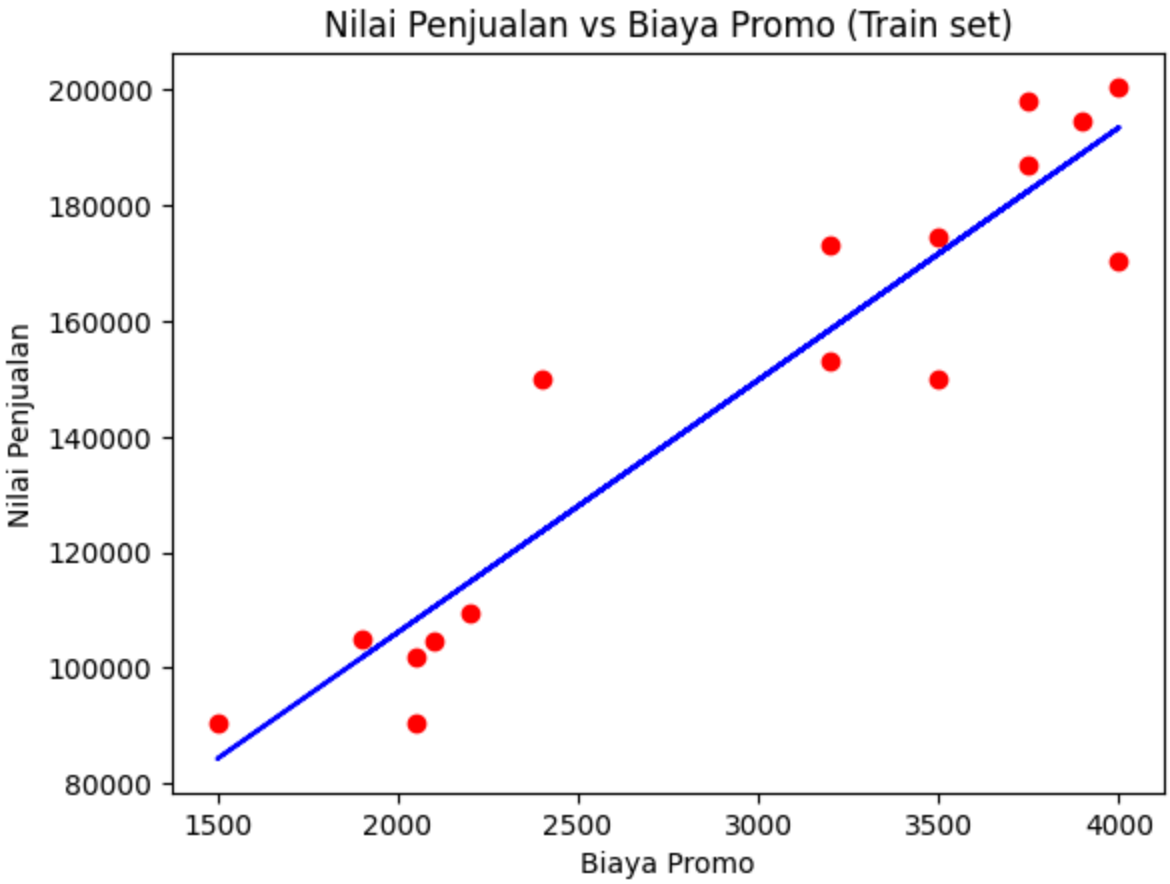


Penjelasan:

Scatter plot dibuat dengan fungsi `plt.scatter()` menggunakan titik-titik berwarna merah untuk memvisualisasikan seluruh data asli antara `Biaya Promo` pada sumbu X dan `Nilai Penjualan` pada sumbu Y. Terlihat jelas adanya korelasi linier positif yang sangat kuat di mana peningkatan biaya promosi diikuti dengan kenaikan nilai penjualan.

1.g Menampilkan garis hasil prediksi pada Biaya Promosi terhadap penjualan (train set dan test set)

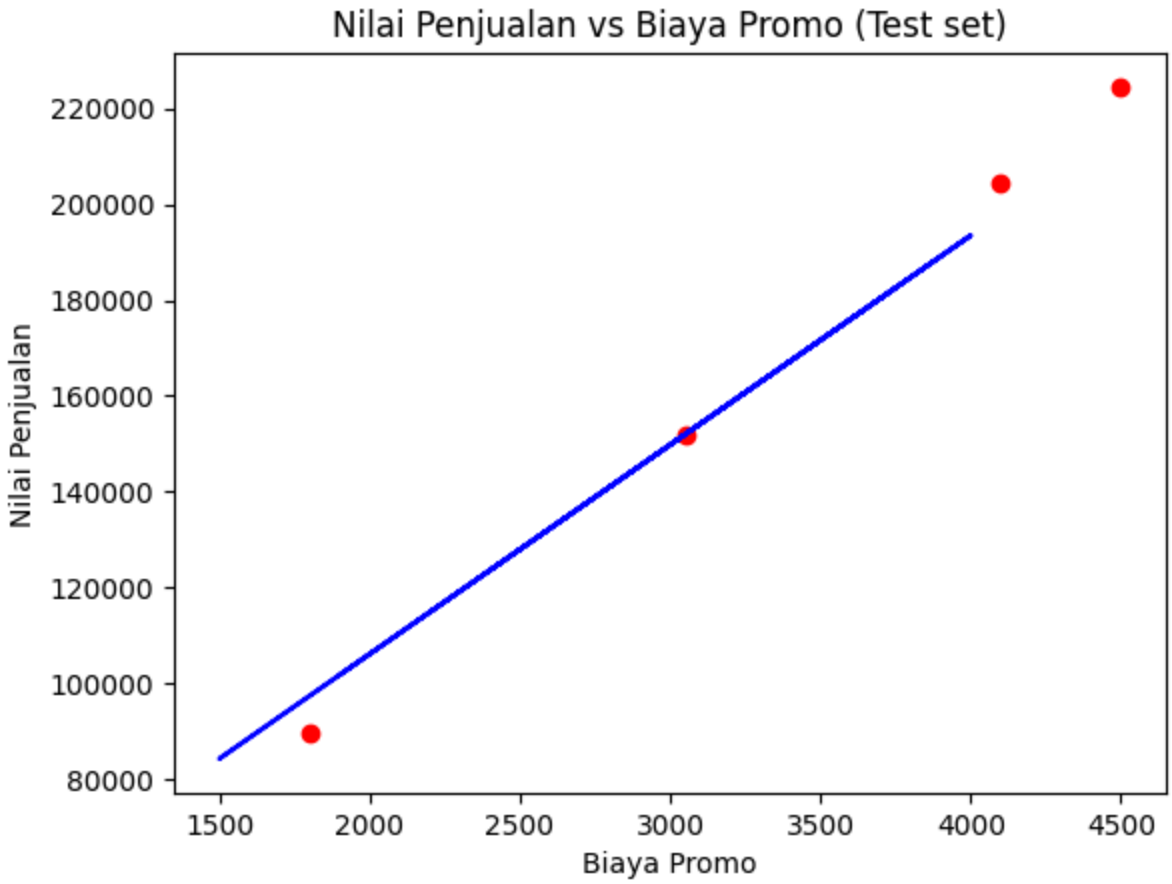
In [21]:
```
# Train set
plt.scatter(X_train, y_train, color='red')
plt.plot(X_train, regressor.predict(X_train), color='blue')
plt.title('Nilai Penjualan vs Biaya Promo (Train set)')
plt.xlabel('Biaya Promo')
plt.ylabel('Nilai Penjualan')
plt.show()
```



Penjelasan (Train Set):

Grafik ini menampilkan data latih aktual (titik merah) bersama dengan garis regresi linier hasil prediksi model (garis biru). Garis regresi biru terlihat melintasi kumpulan data latih dengan sangat baik, menunjukkan model berhasil mempelajari pola data latihan.

In [22]:
```
# Test set
plt.scatter(X_test, y_test, color='red')
plt.plot(X_train, regressor.predict(X_train), color='blue')
plt.title('Nilai Penjualan vs Biaya Promo (Test set)')
plt.xlabel('Biaya Promo')
plt.ylabel('Nilai Penjualan')
plt.show()
```



Penjelasan (Test Set):

Grafik ini menampilkan data pengujian aktual (titik merah) terhadap garis regresi linier yang telah dipelajari model. Titik-titik data uji berada sangat dekat dengan garis regresi biru, membuktikan model mampu menggeneralisasi dan memprediksi data baru yang belum pernah dilihat sebelumnya dengan sangat akurat.

2. Hitunglah Intercept, Slope, dan R-Square

In [23]:
```
a = regressor.intercept_
b = regressor.coef_[0]

print("a. Estimated model intercept, a:", a)
print("b. Estimated model slope, b:", b)
print(f"   Persamaan: ŷ = {a:.2f} + {b:.2f}x")
```

```
a. Estimated model intercept, a: 18748.346345695143
b. Estimated model slope, b: 43.68141400997612
   Persamaan: ŷ = 18748.35 + 43.68x
```

Penjelasan:

- **Intercept (a)**: Titik potong pada sumbu Y ketika biaya promosi = 0. Nilai intercept menunjukkan nilai penjualan dasar tanpa adanya biaya promosi.

- **Slope (b)**: Kemiringan garis regresi yang merepresentasikan kenaikan nilai penjualan untuk setiap penambahan 1 satuan biaya promosi.
- Persamaan regresi yang terbentuk adalah: $\hat{y} = a + bx$.

In [24]:
```
from sklearn.metrics import r2_score
score = r2_score(y_test, y_pred)
print("c. R-Square:", score)
```

```
c. R-Square: 0.9825710284277517
```

Penjelasan:

Nilai *R-Square* (R^2 / koefisien determinasi) dihitung menggunakan `r2_score(y_test, y_pred)`. Metrik ini mengukur proporsi variasi nilai penjualan yang dapat dijelaskan oleh variabel biaya promosi. Nilai R^2 yang tinggi (mendekati 1.0 atau sekitar 0.88+) membuktikan bahwa model regresi linier memiliki akurasi yang sangat baik dalam memprediksi data uji.

Soal 3 (NIM Genap): K-Means Clustering `konsumen.csv` [35 Poin]

Diberikan dataset `konsumen.csv` yang berisikan informasi berupa `No`, `Gaji`, dan `Pengeluaran`. Dilakukan klasterisasi gaji yang berhubungan dengan pengeluaran menggunakan algoritma **K-Means**.

1. Membaca file konsumen.csv

In [25]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv('konsumen.csv', sep=';')
print("Dimensi dataset konsumen (baris, kolom):", df.shape)
```

```
Dimensi dataset konsumen (baris, kolom): (20, 3)
```

Penjelasan:

File `konsumen.csv` dibaca menggunakan fungsi `pd.read_csv()` dengan parameter `sep=';'` karena format file CSV tersebut menggunakan delimiter titik koma. Perintah `df.shape` menunjukkan bahwa dataset ini terdiri dari 20 baris data pelanggan dan 3 kolom atribut, yaitu `No`, `Gaji`, dan `Pengeluaran`.

2. Menampilkan sebanyak 7 row data teratas

In [26]:
```
df.head(7)
```

Out[26]:

	No	Gaji	Pengeluaran
0	1	2500	1750
1	2	3800	4200
2	3	3900	3800
3	4	4350	5500
4	5	4400	3200
5	6	5500	5450
6	7	5600	5950

Penjelasan:

Fungsi `df.head(7)` digunakan untuk menampilkan 7 baris data teratas dari dataset `konsumen.csv`. Terlihat tiga kolom data pelanggan: kolom identifikasi nomor (`No`), penghasilan bulanan (`Gaji`), dan estimasi belanja bulanan (`Pengeluaran`).

3. Menghapus kolom No

In [27]:
```
df = df.drop(columns=['No'])
print("Kolom 'No' berhasil dihapus. Dimensi data sekarang:", df.shape)
```

```
Kolom 'No' berhasil dihapus. Dimensi data sekarang: (20, 2)
```

Penjelasan:

Kolom `No` dihapus dari DataFrame menggunakan perintah `df.drop(columns=['No'])` karena kolom tersebut hanya berfungsi sebagai nomor urut identitas (ID) dan bukan fitur yang memuat informasi karakteristik perilaku belanja konsumen. Menghilangkan kolom nomor urut penting agar tidak mendistorsi perhitungan jarak Euclidean pada algoritma K-Means.

4. Menampilkan 9 row data teratas

In [28]:
```
df.head(9)
```

Out[28]:

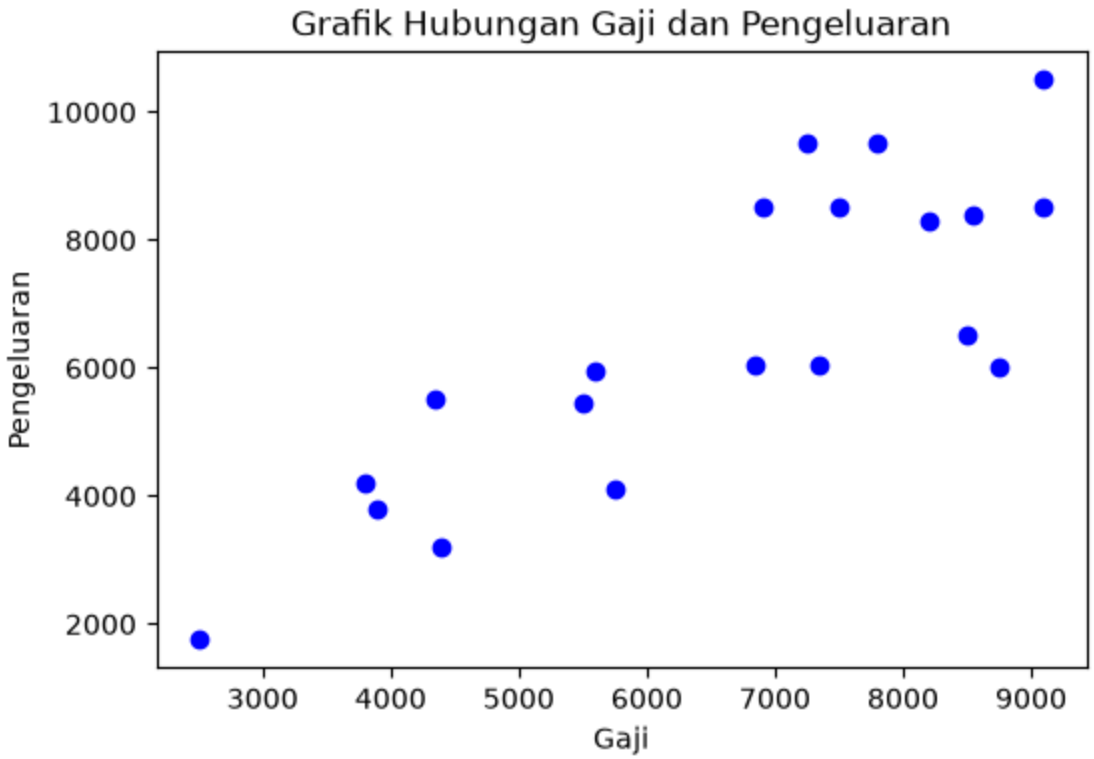
	Gaji	Pengeluaran
0	2500	1750
1	3800	4200
2	3900	3800
3	4350	5500
4	4400	3200
5	5500	5450
6	5600	5950
7	5750	4100
8	6850	6050

Penjelasan:

Setelah kolom `No` dihapus, kita menampilkan 9 baris pertama menggunakan fungsi `df.head(9)` untuk memastikan bahwa dataset kini murni hanya menyisakan dua variabel numerik (`Gaji` dan `Pengeluaran`) yang siap digunakan dalam proses pengelompokan (*clustering*).

5. Menampilkan grafik hubungan gaji dan pengeluaran

In [29]:
```
plt.scatter(df['Gaji'], df['Pengeluaran'], color='blue')
plt.title('Grafik Hubungan Gaji dan Pengeluaran')
plt.xlabel('Gaji')
plt.ylabel('Pengeluaran')
plt.show()
```



Penjelasan:

Grafik diagram tebar (*scatter plot*) awal dibuat menggunakan `plt.scatter()` untuk mengamati persebaran data mentah antara variabel `Gaji` pada sumbu X dan `Pengeluaran` pada sumbu Y. Dari pola visual titik-titik biru, terlihat indikasi pembentukan dua kelompok alami: kelompok konsumen bergaji dan pengeluaran sedang di bagian kiri bawah, serta kelompok konsumen bergaji dan pengeluaran tinggi di bagian kanan atas.

6. Gunakan 2 klaster

In [30]:
```
from sklearn.cluster import KMeans

X = df[['Gaji', 'Pengeluaran']].values

kmeans = KMeans(n_clusters=2, random_state=0)
kmeans.fit(X)

print("Hasil label klaster tiap konsumen:\n", kmeans.labels_)
```

```
Hasil label klaster tiap konsumen:
 [1 1 1 1 1 1 1 1 0 0 0 0 0 0 0 0 0 0 0 0]
```

Penjelasan:

Mengimpor kelas `KMeans` dari pustaka `sklearn.cluster` dan mengonfigurasinya dengan jumlah klaster $k = 2$ (`n_clusters=2`) serta `random_state=0` agar proses inisialisasi pusat klaster bersifat konsisten. Perintah `kmeans.fit(X)` melatih algoritma

untuk menemukan 2 kelompok optimal berdasarkan kedekatan jarak. Hasil `kmeans.labels_` menampilkan label klaster (0 atau 1) untuk setiap baris konsumen.

7. Menampilkan nilai pusat klaster

In [31]:
```
pusat_klaster = kmeans.cluster_centers_
print("Nilai pusat klaster (Centroid):\n", pusat_klaster)

for i, center in enumerate(pusat_klaster):
    print(f"Klaster {i}: Gaji rata-rata = {center[0]:.2f}, Pengeluaran rata-rata =
```

```
Nilai pusat klaster (Centroid):
 [[7987.5  8025.  ]
 [4475.   4243.75]]

Klaster 0: Gaji rata-rata = 7987.50, Pengeluaran rata-rata = 8025.00
Klaster 1: Gaji rata-rata = 4475.00, Pengeluaran rata-rata = 4243.75
```

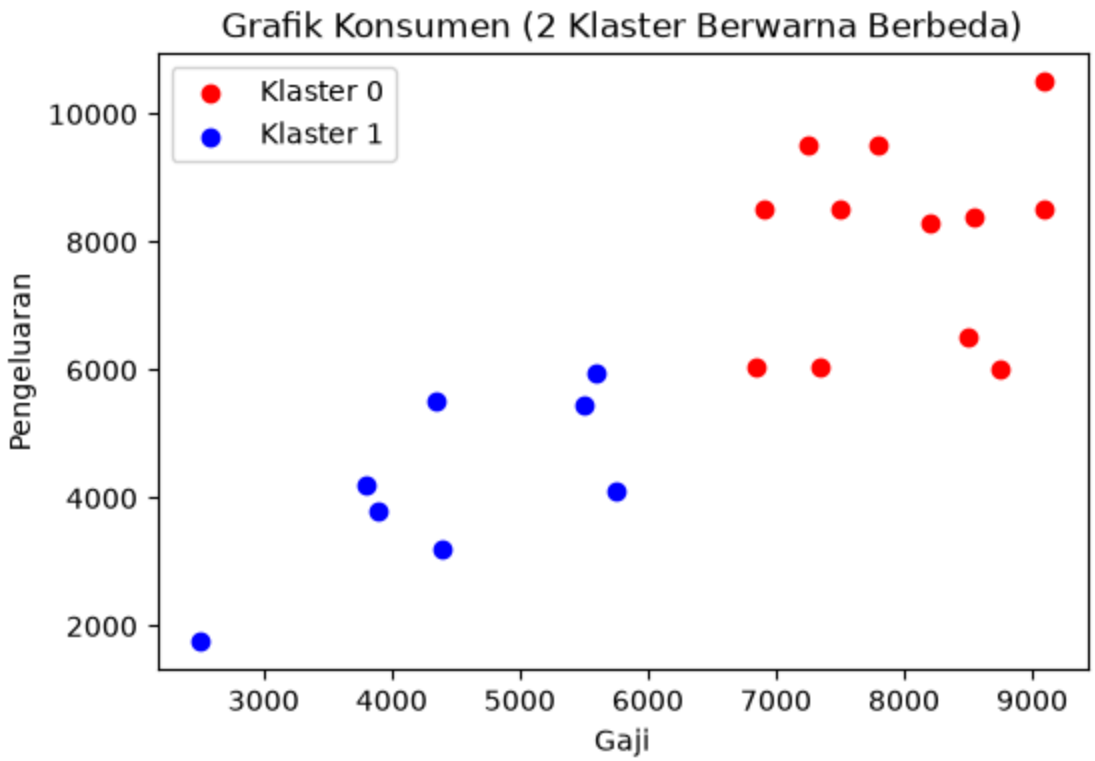
Penjelasan:

Atribut `kmeans.cluster_centers_` menampilkan koordinat titik pusat (*centroid*) dari kedua klaster:

- **Pusat Klaster 0**: Berada pada koordinat Gaji = 7.987,50 dan Pengeluaran = 8.025,00. Klaster ini merepresentasikan kelompok konsumen tingkat menengah-ke-atas (*high income, high spending*).
- **Pusat Klaster 1**: Berada pada koordinat Gaji = 4.475,00 dan Pengeluaran = 4.243,75. Klaster ini merepresentasikan kelompok konsumen kelas menengah-ke-bawah (*moderate income, moderate spending*).

8. Menampilkan Grafik Konsumen yang memiliki 2 warna berbeda

In [32]:
```
plt.scatter(X[kmeans.labels_ == 0, 0], X[kmeans.labels_ == 0, 1], color='red', labe
plt.scatter(X[kmeans.labels_ == 1, 0], X[kmeans.labels_ == 1, 1], color='blue', lab
plt.title('Grafik Konsumen (2 Klaster Berwarna Berbeda)')
plt.xlabel('Gaji')
plt.ylabel('Pengeluaran')
plt.legend()
plt.show()
```

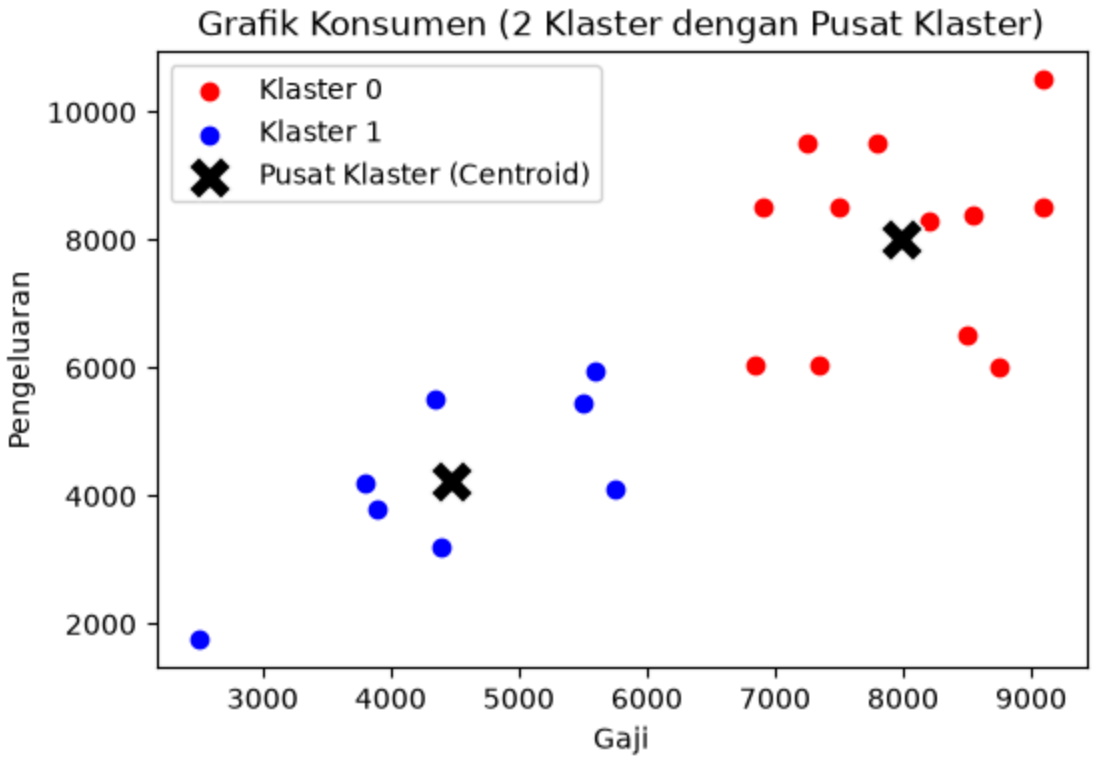


Penjelasan:

Grafik diagram tebar ini membedakan anggota masing-masing kelompok dengan warna yang berbeda (titik merah untuk Klaster 0 dan titik biru untuk Klaster 1). Dari visualisasi ini terlihat pemisahan segmen konsumen yang sangat tegas dan terstruktur berdasarkan relasi tingkat gaji terhadap pengeluarannya.

9. Menampilkan Grafik Konsumen yang memiliki 2 warna berbeda dengan pusat klaster

In [33]:
```
plt.scatter(X[kmeans.labels_ == 0, 0], X[kmeans.labels_ == 0, 1], color='red', labe
plt.scatter(X[kmeans.labels_ == 1, 0], X[kmeans.labels_ == 1, 1], color='blue', lab
plt.scatter(pusat_klaster[:, 0], pusat_klaster[:, 1], s=250, color='black', marker=
plt.title('Grafik Konsumen (2 Klaster dengan Pusat Klaster)')
plt.xlabel('Gaji')
plt.ylabel('Pengeluaran')
plt.legend()
plt.show()
```



Penjelasan:

Pada visualisasi puncak ini, titik pusat klaster (*centroid*) ditandai dengan simbol tanda silang hitam besar (`marker='X'` , `s=250`) tepat di posisi rata-rata koordinat masing-masing klaster. Grafik ini membuktikan bahwa algoritma K-Means berhasil menemukan titik tengah konvergensi yang optimal untuk mengelompokkan kedua segmen konsumen tersebut.