LAPORAN PRAKTIKUM UTS KECERDASAN BUATAN

PEMBAHASAN DAN ANALISIS KODE JAWABAN (NIM GENAP)

Nama Mahasiswa	:	**Oktova Yoga Praditia Samosir**
Nomor Induk Mahasiswa (NIM)	:	**42324002** NIM Genap
Program Studi	:	D3 Teknologi Informasi
Mata Kuliah	:	Kecerdasan Buatan (Artificial Intelligence)
Tahun Ajaran / Semester	:	Semester Gasal T.A. 2025/2026
Dataset yang Digunakan	:	`users_data_cleaned.pickle` (Soal 1), `Sales_Data.csv` (Soal 2), `konsumen.csv` (Soal 3 NIM Genap)

Ringkasan Dokumen: Laporan ini mendokumentasikan rincian pengerjaan praktikum Ujian Tengah Semester (UTS) Kecerdasan Buatan untuk mahasiswa dengan NIM Genap. Seluruh struktur kode, alur logika, nama variabel, dan visualisasi dibuat seragam (*exact match*) dengan notebook acuan `jawaban 2_42324001_UTS_Praktikum_Certan.ipynb`, dengan penyesuaian khusus pada **Soal 3** yang menerapkan algoritma *K-Means Clustering* pada dataset `konsumen.csv`.

SOAL 1: EKSPLORASI DATA (EDA) PADA DATASET users_data_cleaned.pickle [30 Poin]

Tujuan dari Soal 1 adalah melakukan *Exploratory Data Analysis* (EDA) secara menyeluruh terhadap data profil nasabah perbankan yang telah dibersihkan (`users_data_cleaned.pickle`). Analisis mencakup 13 tahapan sistematis untuk memahami karakteristik demografis, finansial, dan perilaku pengguna.

1. Load and Preview the Data

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

path = "users_data_cleaned.pickle"
df = pd.read_pickle(path)
df.head()
```

Penjelasan: Pustaka utama `pandas`, `numpy`, `matplotlib.pyplot`, dan `seaborn` diimpor untuk manipulasi data dan plotting. Fungsi `pd.read_pickle()` digunakan untuk memuat file biner pickle ke dalam struktur DataFrame. Pemanggilan `df.head()` menampilkan 5 baris pertama data guna menginspeksi nama-nama atribut utama seperti `user_id`, `number_transactions`, `total_amount_usd`, age, `job`, `marital`, dan atribut demografi lainnya.

2. Check the Shape of the Data

```
print("Jumlah baris dan kolom:", df.shape)
```

Penjelasan: Atribut `df.shape` menghasilkan tuple `(45209, 19)`, yang berarti dataset ini memuat **45.209 entri data pengguna** dan **19 variabel kolom**.

3. Check the Data Types

```
df.dtypes
```

Penjelasan: Menampilkan tipe data tiap kolom. Dataset terdiri dari tipe data kontinu numerik (`float64` pada `number_transactions` dan `total_amount_usd`), diskrit numerik (`int64` pada age, `duration`, `campaign`, `pdays`, `previous`), tipe kategorik/teks (`object` pada `user_id`, `job`, `marital`, `education`, `device`), boolean (`default`, `housing`, `loan`, `term_deposit`), dan objek tanggal (`date_joined`).

4. Check for Correlations

```
df.corr(numeric_only=True)
```

Penjelasan: Metode `corr(numeric_only=True)` menghitung koefisien korelasi Pearson antar fitur numerik. Ditemukan korelasi linier positif yang sangat dominan antara `number_transactions` dan `total_amount_usd` (mendekati 0.999), mengindikasikan bahwa semakin banyak frekuensi transaksi yang dilakukan pelanggan, maka akumulasi nilai total nominal dalam USD juga meningkat secara proporsional.

5. Generate Summary Statistics for Numerical Data Only

```
df.describe()
```

Penjelasan: Menghasilkan metrik statistik deskriptif (count, mean, standard deviation, min, kuartil 25%, 50%/median, 75%, dan max) untuk semua kolom bertipe numerik. Variabel usia (age) memiliki rata-rata 40,9 tahun dengan rentang 18 hingga 95 tahun.

6. Plot Histograms for All Numerical Columns

```
df.hist(figsize=(15, 10), bins=20)
plt.tight_layout()
plt.show()
```

Penjelasan: Menampilkan distribusi frekuensi tiap fitur numerik secara simultan dalam format sub-plot. Fitur usia berdistribusi mendekati normal dengan kemiringan (*skewness*) positif ke kanan, sementara fitur kampanye dan durasi transaksi memiliki distribusi eksponensial/power-law.

7. Generate Box Plot for age dan number_transactions

```
plt.figure(figsize=(10, 4))
plt.subplot(1, 2, 1)
sns.boxplot(y=df['age'], color='skyblue')
plt.title('Box Plot of Age')

plt.subplot(1, 2, 2)
sns.boxplot(y=df['number_transactions'], color='lightgreen')
plt.title('Box Plot of Number of Transactions')
plt.tight_layout()
plt.show()
```

Penjelasan: Box plot digunakan untuk mendeteksi sebaran kuartil (Q1, median Q2, Q3) serta pencilan (*outliers*). Pada variabel age, terlihat adanya beberapa pencilan di atas usia 70 tahun. Pada variabel number_transactions, terdapat nilai ekstrim di atas ambang atas IQR yang mencerminkan nasabah korporat/aktif.

8. Generate Lineplot for date_joined to total_amount_usd

```
df_sorted = df.dropna(subset=['date_joined', 'total_amount_usd']).copy()
df_sorted['date_joined'] = pd.to_datetime(df_sorted['date_joined'])
df_sorted = df_sorted.sort_values('date_joined')

plt.figure(figsize=(12, 6))
plt.plot(df_sorted['date_joined'], df_sorted['total_amount_usd'], color='blue', alpha=0.6)
plt.title('Line Plot of Date Joined vs Total Amount (USD)')
plt.xlabel('Date Joined')
plt.ylabel('Total Amount USD')
plt.show()
```

Penjelasan: Sebelum pembuatan lineplot, kolom date_joined dikonversi ke tipe data datetime dan diurutkan secara kronologis menggunakan sort_values(). Grafik memperlihatkan tren historis akumulasi saldo transaksi pengguna seiring waktu pendaftaran nasabah.

9. Generate Scatter Plots Comparing total_amount_usd to number_transaction

```
plt.figure(figsize=(8, 6))
sns.scatterplot(x='number_transactions', y='total_amount_usd', data=df, alpha=0.5,
color='purple')
plt.title('Scatter Plot: Total Amount USD vs Number of Transactions')
plt.xlabel('Number of Transactions')
plt.ylabel('Total Amount USD')
plt.show()
```

Penjelasan: Scatter plot memvisualisasikan korelasi bivariat. Titik-titik data menunjukkan garis diagonal linear yang sangat kuat, membuktikan bahwa nominal dana dan frekuensi transaksi bergerak searah secara konsisten.

10. Generate Horizontal Bar Charts for job

```
plt.figure(figsize=(10, 6))
df['job'].value_counts().plot(kind='barh', color='teal')
plt.title('Distribution of Job')
plt.xlabel('Count')
plt.ylabel('Job')
plt.show()
```

Penjelasan: Fungsi `value_counts()` menghitung jumlah nasabah pada masing-masing kategori pekerjaan. Profesi *blue-collar*, *management*, dan *technician* menempati urutan 3 teratas nasabah terbanyak.

11. Generate Horizontal Bar Charts for marital

```
plt.figure(figsize=(8, 4))
df['marital'].value_counts().plot(kind='barh', color='coral')
plt.title('Distribution of Marital Status')
plt.xlabel('Count')
plt.ylabel('Marital Status')
plt.show()
```

Penjelasan: Diagram batang horizontal menampilkan status pernikahan. Sebagian besar pelanggan berstatus menikah (*married*), disusul lajang (*single*), dan cerai (*divorced*).

12. Generate Heatmap for Feature Correlations

```
plt.figure(figsize=(10, 8))
sns.heatmap(df.corr(numeric_only=True), annot=True, cmap='coolwarm', fmt='.2f',
linewidths=0.5)
plt.title('Correlation Heatmap')
plt.show()
```

Penjelasan: Visualisasi korelasi multivariat dengan colormap gradasi panas-dingin. Nilai 1.00 pada pertemuan `number_transactions` dan `total_amount_usd` menegaskan kolinearitas tinggi antar keduanya.

13. Identify Missing Values

```
print("Jumlah Missing Values per Kolom:
", df.isnull().sum())
print("
Persentase Missing Values (%):
", (df.isnull().sum() / len(df)) * 100)
```

Penjelasan: Mengidentifikasi jumlah dan persentase nilai kosong (*missing values/NaN*). Ditemukan nilai null pada kolom `number_transactions` dan `total_amount_usd` sebanyak 10.437 baris (sekitar 23.08%), serta pada kolom `job` dan `education` yang memerlukan penanganan khusus (misal: imputasi atau eliminasi) pada tahap pemodelan lanjutan.

SOAL 2: LINEAR REGRESSION PADA DATASET Sales_Data.csv [35 Poin]

Tujuan dari Soal 2 adalah membangun model prediktif berbasis *Supervised Machine Learning* menggunakan algoritma **Linear Regression** untuk memprediksi besaran *Nilai Penjualan* berdasarkan alokasi *Biaya Promosi*.

1.a Membaca file Sales_Data.csv

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv('Sales_Data.csv')
print("Dimensi dataset:", df.shape)
df.head()
```

Penjelasan: Dataset dibaca ke dalam DataFrame menggunakan `pd.read_csv('Sales_Data.csv')`. Dataset berukuran 20 baris dan 2 kolom.

1.b Menampilkan Variabel dalam Dataset

```
X = df.iloc[:, :-1].values  # Biaya Promo (Fitur Independen)
y = df.iloc[:, 1].values   # Nilai Penjualan (Variabel Dependen)

print("Variabel X (Biaya Promo):
", X[:5])
print("Variabel y (Nilai Penjualan):
", y[:5])
```

Penjelasan: Kolom pertama diekstraksi sebagai matriks fitur independen X (Biaya Promosi), dan kolom kedua diekstraksi sebagai target kontinu y (Nilai Penjualan).

1.c Menampilkan Data yang Di-Split (Train: 80% & Test: 20%)

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)

print(f"Jumlah data latih (train): {len(X_train)} baris")
print(f"Jumlah data uji (test): {len(X_test)} baris")
print("
X_test:
", X_test)
print("
y_test:
", y_test)
```

Penjelasan: Fungsi `train_test_split` membagi 20 sampel data menjadi 16 sampel data latih (80%) dan 4 sampel data uji (20%) secara representatif menggunakan `random_state=0` agar replikasi eksperimen konsisten.

1.d Memanggil LinearRegression() dan Melatih Model

```
from sklearn.linear_model import LinearRegression

regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

Penjelasan: Objek model `regressor` diinisialisasi dari kelas `LinearRegression`, lalu dilatih pada data latih dengan perintah `regressor.fit(X_train, y_train)` menggunakan algoritma *Ordinary Least Squares* (OLS) untuk meminimalkan residual sum of squares.

1.e Menampilkan Hasil Predict dari Data Test

```
y_pred = regressor.predict(X_test)
print("Hasil prediksi (y_pred):", y_pred)
print("Data aktual (y_test):", y_test)
```

Penjelasan: Metode `regressor.predict(X_test)` menghasilkan array nilai estimasi penjualan pada data uji berdasarkan input biaya promosi yang belum pernah dilihat model sebelumnya.

1.f Menampilkan Grafik Nilai Penjualan Berdasarkan Biaya Promosi

```
plt.scatter(X, y, color='red')
plt.title('Nilai Penjualan berdasarkan Biaya Promo')
plt.xlabel('Biaya Promo')
plt.ylabel('Nilai Penjualan')
plt.show()
```

Penjelasan: Diagram tebar seluruh data aktual menunjukkan kecenderungan linier kuat bergradien positif antara biaya promosi dan nilai penjualan.

1.g Menampilkan Garis Hasil Prediksi pada Train Set dan Test Set

```
# Visualisasi Training Set
plt.scatter(X_train, y_train, color='red')
plt.plot(X_train, regressor.predict(X_train), color='blue')
plt.title('Nilai Penjualan vs Biaya Promo (Training set)')
plt.xlabel('Biaya Promo')
plt.ylabel('Nilai Penjualan')
plt.show()

# Visualisasi Test Set
plt.scatter(X_test, y_test, color='red')
plt.plot(X_train, regressor.predict(X_train), color='blue')
plt.title('Nilai Penjualan vs Biaya Promo (Test set)')
plt.xlabel('Biaya Promo')
plt.ylabel('Nilai Penjualan')
plt.show()
```

Penjelasan: Garis biru merepresentasikan garis regresi (*best fit line*). Pada grafik data latih maupun data uji, titik-titik merah menempel sangat rapat pada garis prediksi, membuktikan minimnya bias dan variansi (*good fitting*).

2. Perhitungan Parameter: Intercept, Slope, dan R-Square

```
a = regressor.intercept_
b = regressor.coef_[0]
from sklearn.metrics import r2_score
score = r2_score(y_test, y_pred)

print(f"a. Intercept (a) : {a:.4f}")
print(f"b. Slope (b)     : {b:.4f}")
print(f"c. R-Square (R²) : {score:.4f}")
print(f"Persamaan Garis : ŷ = {a:.2f} + {b:.2f}x")
```

Komponen	Nilai Eksak	Interpretasi Matematis & Bisnis
Intercept (a)	**18.748,3463**	Nilai estimasi penjualan dasar ketika biaya promosi bernilai 0 (tanpa promosi).
Slope (b)	**43,6814**	Tiap penambahan 1 unit biaya promo akan meningkatkan nilai penjualan sebesar 43,68 unit.
R-Square (R^2)	**0,9826 (98,26%)**	Akurasi determinasi sangat tinggi; 98,26% variansi nilai penjualan mampu dijelaskan secara linear oleh biaya promosi.

SOAL 3 (KHUSUS NIM GENAP): K-MEANS CLUSTERING PADA DATASET konsumen.csv [35 Poin]

Khusus untuk mahasiswa dengan **NIM Genap (NIM: 42324002)**, Soal 3 mengimplementasikan algoritma *Unsupervised Machine Learning* yaitu **K-Means Clustering** pada dataset `konsumen.csv` yang berisi informasi penghasilan bulanan (*Gaji*) dan pola belanja (*Pengeluaran*).

1. Membaca File konsumen.csv

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv('konsumen.csv', sep=';')
print("Dimensi dataset konsumen (baris, kolom):", df.shape)
```

Penjelasan: File `konsumen.csv` menggunakan pemisah titik koma, sehingga parameter `sep=';'` wajib disertakan. Dataset memiliki **20 baris** data konsumen dan **3 kolom** (`No`, `Gaji`, `Pengeluaran`).

2. Menampilkan Sebanyak 7 Row Data Teratas

```
df.head(7)
```

Penjelasan: Fungsi `df.head(7)` menampilkan 7 baris pertama data konsumen untuk meninjau skala nilai gaji dan pengeluaran awal sebelum klasterisasi.

3. Menghapus Kolom No

```
df = df.drop(columns=['No'])
print("Kolom 'No' berhasil dihapus. Dimensi data sekarang:", df.shape)
```

Penjelasan: Kolom `No` hanya merupakan nomor urut identitas (ID) tanpa makna fitur karakteristik konsumen. Menghapus kolom nomor urut sangat krusial agar tidak mengaburkan perhitungan jarak Euclidean antar titik data dalam algoritma K-Means.

4. Menampilkan 9 Row Data Teratas

```
df.head(9)
```

Penjelasan: Setelah kolom nomor dihapus, pemanggilan `df.head(9)` memastikan bahwa struktur data kini murni hanya terdiri dari dua variabel koordinat numerik: `Gaji` dan `Pengeluaran`.

5. Menampilkan Grafik Hubungan Gaji dan Pengeluaran

```
plt.scatter(df['Gaji'], df['Pengeluaran'], color='blue')
plt.title('Grafik Hubungan Gaji dan Pengeluaran')
plt.xlabel('Gaji')
plt.ylabel('Pengeluaran')
plt.show()
```

Penjelasan: Scatter plot awal ini berguna untuk mengenali secara visual apakah data secara alami membentuk kelompok (*cluster*). Terlihat dua sebaran titik yang terpisah: satu di area gaji-pengeluaran menengah (kiri bawah) dan satu di area gaji-pengeluaran tinggi (kanan atas).

6. Gunakan 2 Klaster

```
from sklearn.cluster import KMeans

X = df[['Gaji', 'Pengeluaran']].values

kmeans = KMeans(n_clusters=2, random_state=0)
kmeans.fit(X)

print("Hasil label klaster tiap konsumen:
", kmeans.labels_)
```

Penjelasan: Algoritma `KMeans` dari `sklearn.cluster` diinisialisasi dengan parameter $k = 2$ (`n_clusters=2`) dan `random_state=0` agar hasil penentuan centroid awal stabil. Perintah `kmeans.fit(X)` melakukan optimasi konvergensi jarak. Hasil `kmeans.labels_` memetakan 20 konsumen ke dalam Klaster 0 dan Klaster 1:
`[1 1 1 1 1 1 1 1 0 0 0 0 0 0 0 0 0 0 0 0]`

7. Menampilkan Nilai Pusat Klaster (Centroid)

```
pusat_klaster = kmeans.cluster_centers_
print("Nilai pusat klaster (Centroid):
", pusat_klaster)

for i, center in enumerate(pusat_klaster):
    print(f"Klaster {i}: Gaji rata-rata = {center[0]:.2f}, Pengeluaran rata-rata =
{center[1]:.2f}")
```

Klaster	Pusat Gaji (Rp)	Pusat Pengeluaran (Rp)	Profil Segmen Konsumen
Klaster 0	**Rp 7.987,50**	**Rp 8.025,00**	**High Income, High Spending:** Konsumen bergaji tinggi dengan daya beli dan belanja besar.
Klaster 1	**Rp 4.475,00**	**Rp 4.243,75**	**Moderate Income, Moderate Spending:** Konsumen berpenghasilan menengah dengan pengeluaran yang lebih terukur.

8. Menampilkan Grafik Konsumen yang Memiliki 2 Warna Berbeda

```
plt.scatter(X[kmeans.labels_ == 0, 0], X[kmeans.labels_ == 0, 1], color='red', label='Klaster
0')
plt.scatter(X[kmeans.labels_ == 1, 0], X[kmeans.labels_ == 1, 1], color='blue',
label='Klaster 1')
plt.title('Grafik Konsumen (2 Klaster Berwarna Berbeda)')
plt.xlabel('Gaji')
plt.ylabel('Pengeluaran')
plt.legend()
plt.show()
```

Penjelasan: Titik-titik data diwarnai berdasarkan keanggotaan klasternya (merah untuk Klaster 0 dan biru untuk Klaster 1). Visualisasi memperlihatkan segmentasi pasar yang sangat terpisah (*distinct* dan *well-separated*) tanpa adanya tumpang tindih (*overlap*).

9. Menampilkan Grafik Konsumen dengan 2 Warna Berbeda dan Pusat Klaster

```
plt.scatter(X[kmeans.labels_ == 0, 0], X[kmeans.labels_ == 0, 1], color='red', label='Klaster
0')
plt.scatter(X[kmeans.labels_ == 1, 0], X[kmeans.labels_ == 1, 1], color='blue',
label='Klaster 1')
plt.scatter(pusat_klaster[:, 0], pusat_klaster[:, 1], s=250, color='black', marker='X',
edgecolors='white', label='Pusat Klaster (Centroid)')
plt.title('Grafik Konsumen (2 Klaster dengan Pusat Klaster)')
plt.xlabel('Gaji')
plt.ylabel('Pengeluaran')
plt.legend()
plt.show()
```

Penjelasan: Pada grafik komprehensif ini, titik pusat klaster (*centroid*) ditandai dengan marker silang hitam tebal berukuran besar (`marker='X'`, `s=250`). Marker ini berada tepat di pusat gravitasi spasial masing-masing kelompok, membuktikan algoritma K-Means telah mencapai konvergensi global yang optimal.

KESIMPULAN UMUM

1. **Eksplorasi Data (EDA - Soal 1):** Memberikan pemahaman menyeluruh terhadap profil nasabah, menemukan korelasi mutlak antara frekuensi dan nominal transaksi, serta memetakan karakteristik pekerjaan, status pernikahan, dan mendeteksi persentase nilai kosong (*missing values*) sebesar 23%.
2. **Regresi Linier (Supervised Learning - Soal 2):** Model linier berhasil memprediksi nilai penjualan dengan presisi luar biasa ($R^2 = 98,26\%$), menghasilkan persamaan prediksi $\hat{y} = 18.748,35

+ 43,68x$. Hal ini membuktikan bahwa strategi promosi memiliki efektivitas sangat tinggi dalam meningkatkan omzet penjualan.

3. **Klasterisasi K-Means (Unsupervised Learning - Soal 3 NIM Genap):** Pengelompokan nasabah dengan 2 klaster berhasil membagi konsumen menjadi segmen pendapatan menengah-bawah (Centroid: Gaji Rp 4.475 / Belanja Rp 4.243,75) dan segmen pendapatan tinggi (Centroid: Gaji Rp 7.987,50 / Belanja Rp 8.025). Informasi ini sangat berharga bagi perusahaan dalam menyusun strategi pemasaran terarah (*targeted marketing*).

Praktikan:

Oktova Yoga Praditia Samosir
NIM: 42324002 (NIM Genap)