Laporan Praktikum

UTS Praktikum



4233201 – Kecerdasan Buatan

11322004_Destina Manurung

Prodi : D3 Teknologi Informasi

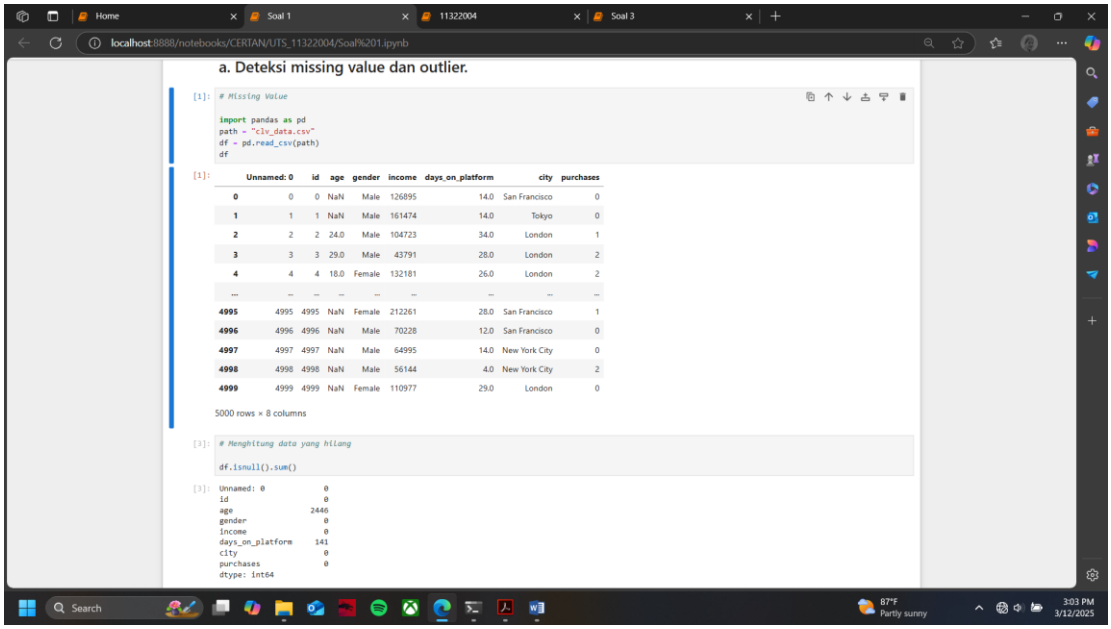
INSTITUT TEKNOLOGI DEL

FAKULTAS VOKASI

Soal 1

Dari *dataset* 'clv_data.csv', tentukan :

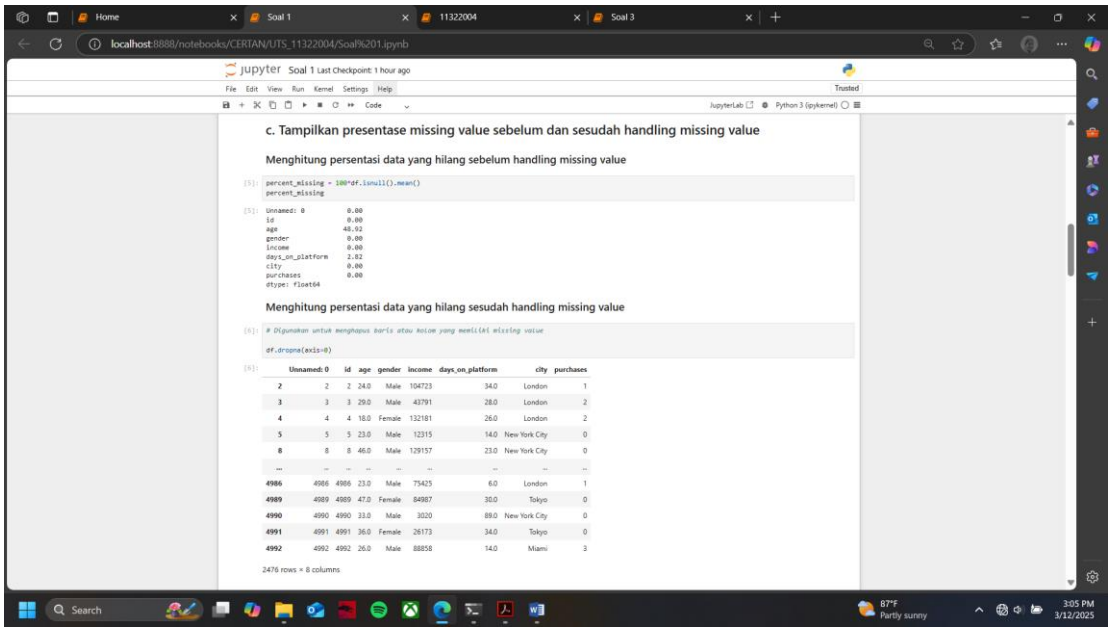
a. Deteksi *missing value* dan *outlier*.



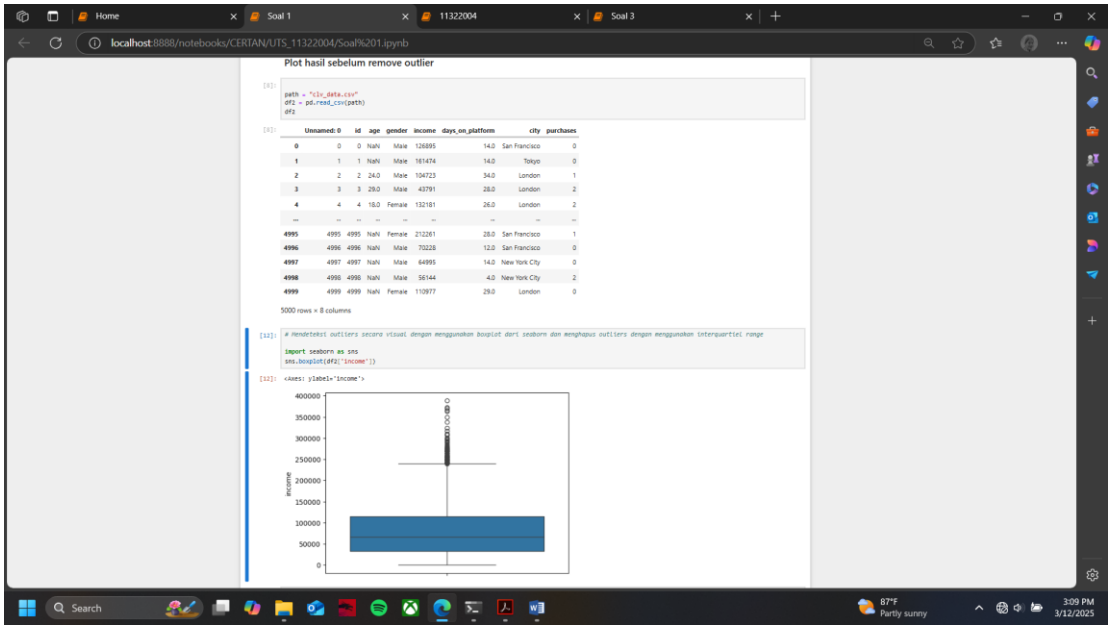
b. Imputasi *missing value* menggunakan *mean* atau *median*. Jelaskan alasan pemilihan *mean*/*median*.

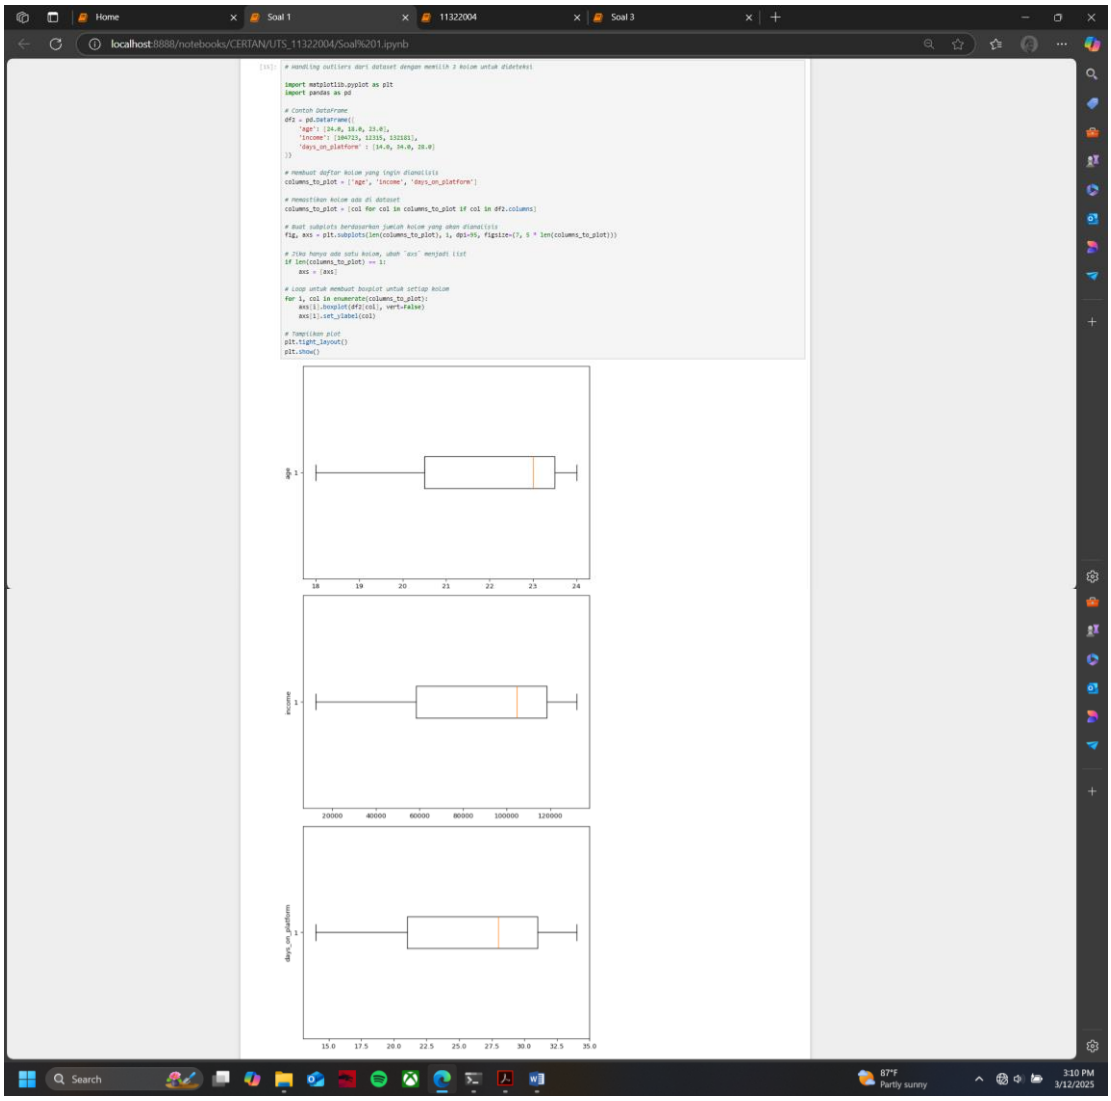


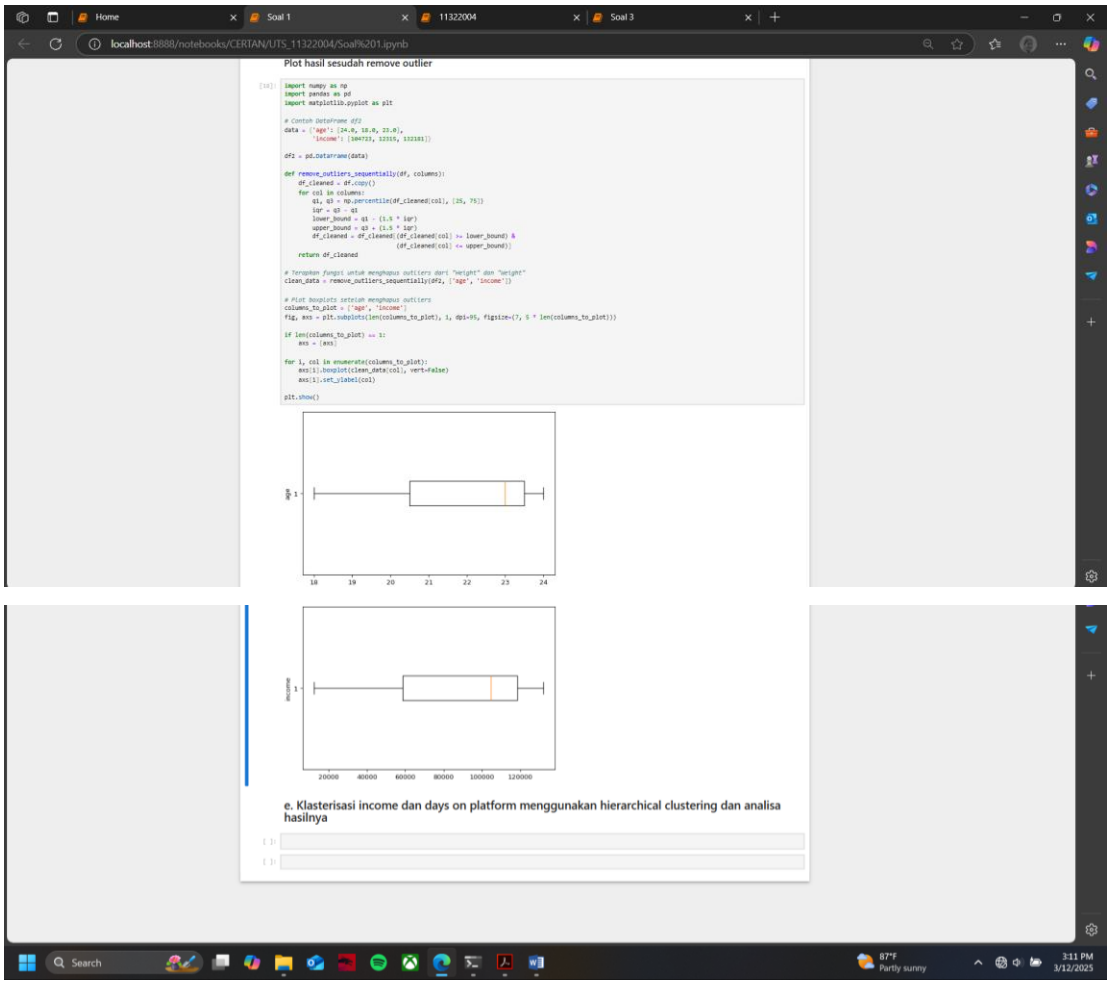
c. Tampilkan presentase *missing value* sebelum dan sesudah *handling missing value*.



d. *Remove outlier* (Plot hasil sebelum dan sesudah *remove outlier*).

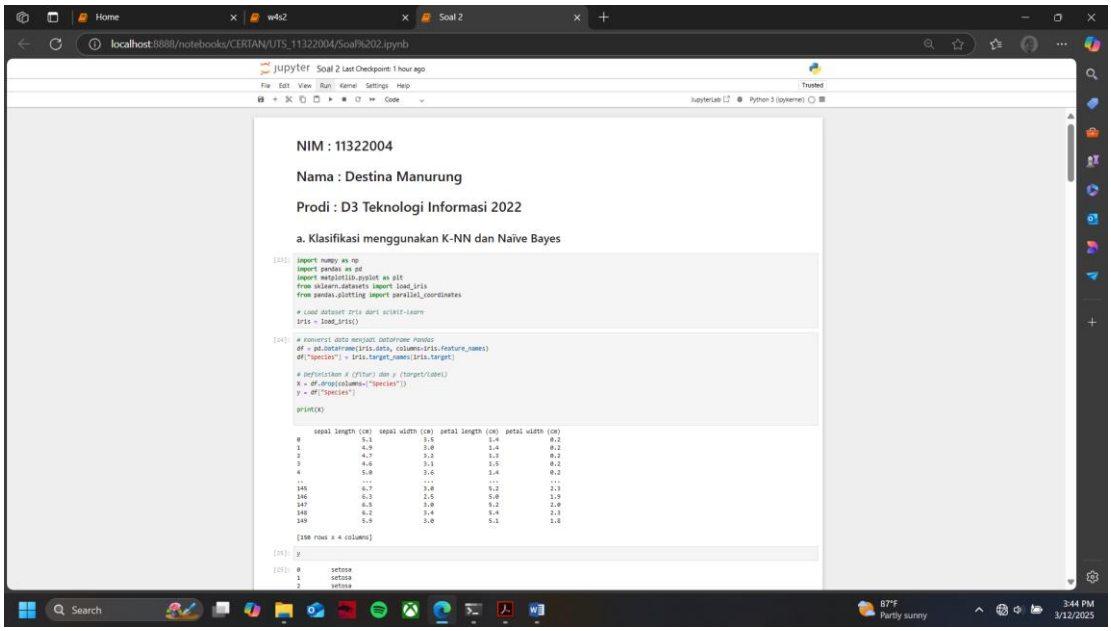


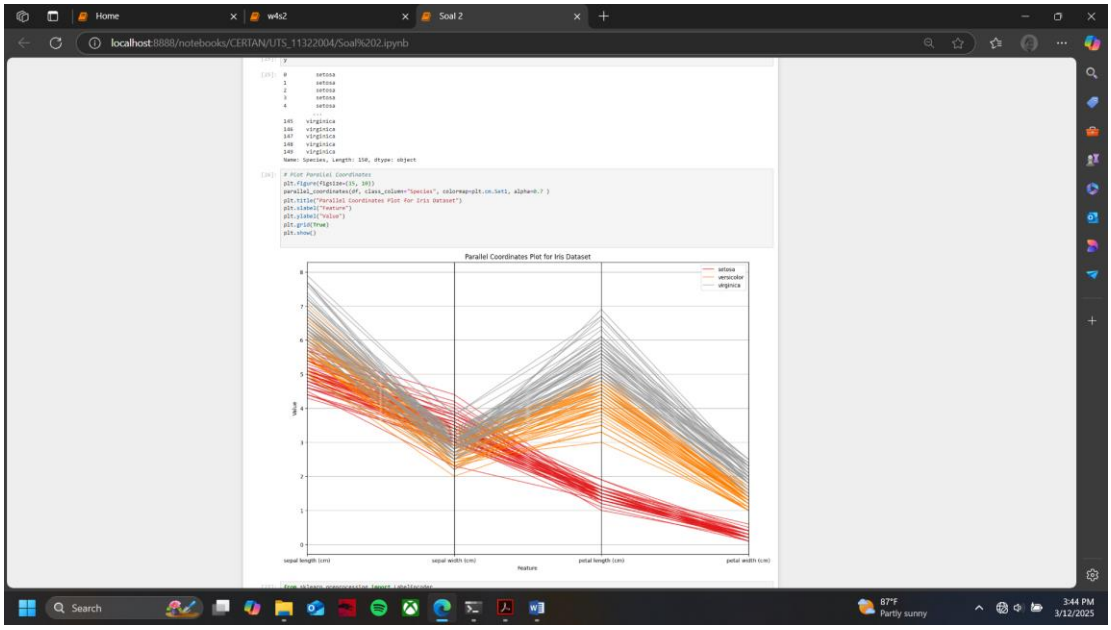

Home
Soal 1
11322004
Soal 3
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%201.ipynb
[15]:
Handling outliers dari dataset dengan memilih 3 kolom untuk dideteksi
import matplotlib.pyplot as plt
import pandas as pd
Contoh DataFrame
df2 = pd.DataFrame({
'Age' : [24.0, 18.0, 23.0],
'Income' : [104723, 12315, 132181],
'days_on_platform' : [14.0, 34.0, 28.0]
})
Membuat daftar kolom yang ingin dianalisis
columns_to_plot = ['Age', 'Income', 'days_on_platform']
Memastikan kolom ada di dataset
columns_to_plot = [col for col in columns_to_plot if col in df2.columns]
Buat subplots berdasarkan jumlah kolom yang akan dianalisis
fig, axs = plt.subplots(len(columns_to_plot), 1, dpi=95, figsize=(7, 5 * len(columns_to_plot)))
Jika hanya ada satu kolom, ubah `axs` menjadi list
if len(columns_to_plot) == 1:
axs = [axs]
Loop untuk membuat boxplot untuk setiap kolom
for i, col in enumerate(columns_to_plot):
axs[i].boxplot(df2[col], vert=False)
axs[i].set_ylabel(col)
Tampilkan plot
plt.tight_layout()
plt.show()
Age
Income
days_on_platform
Search
87°F
Partly sunny
3:10 PM
3/12/2025

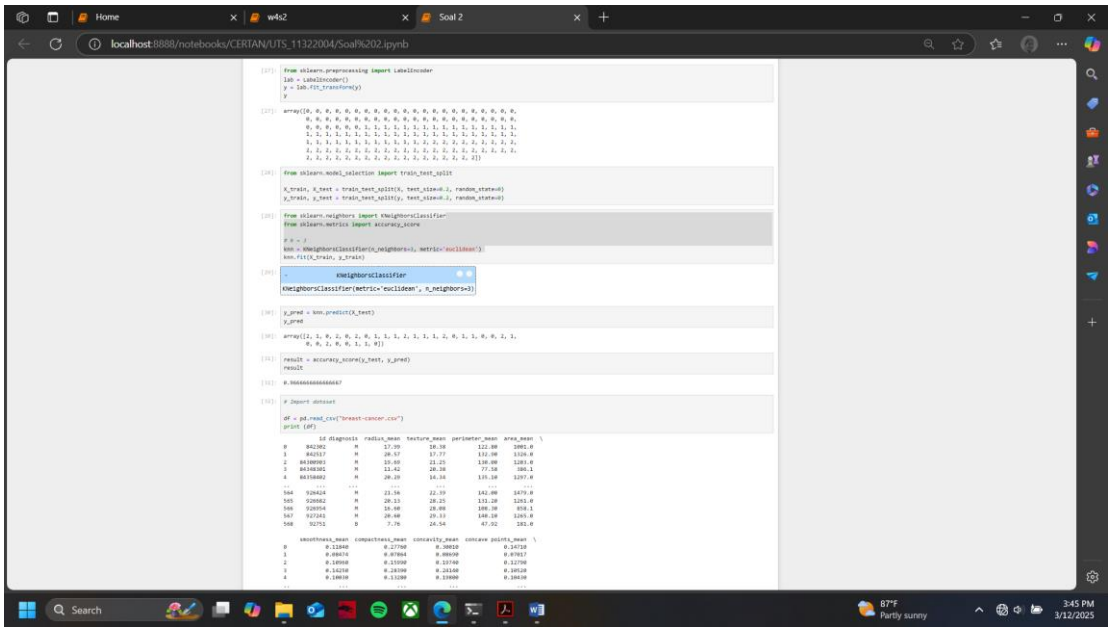


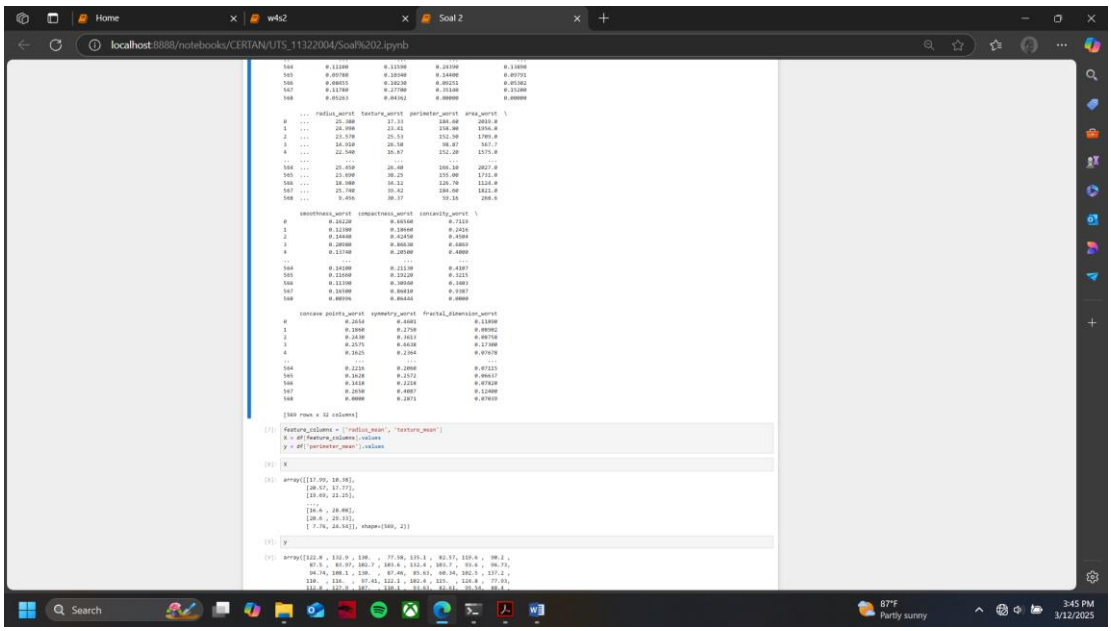
e. Klasterisasi *income* dan *days on platform* menggunakan *hierarchical clustering* dan analisa hasilnya

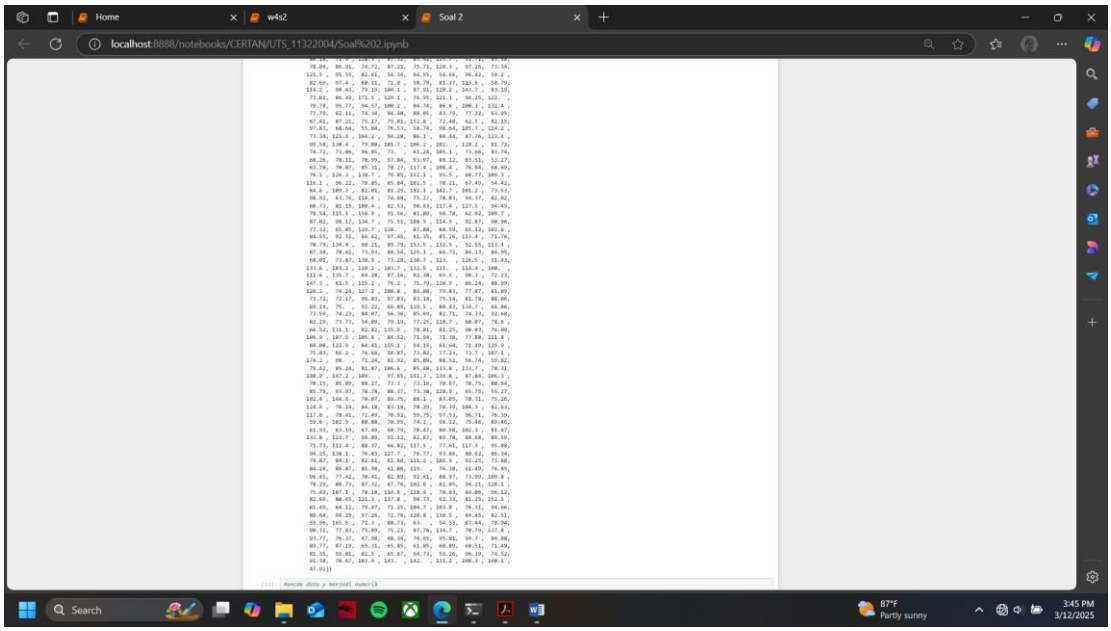
Soal 2

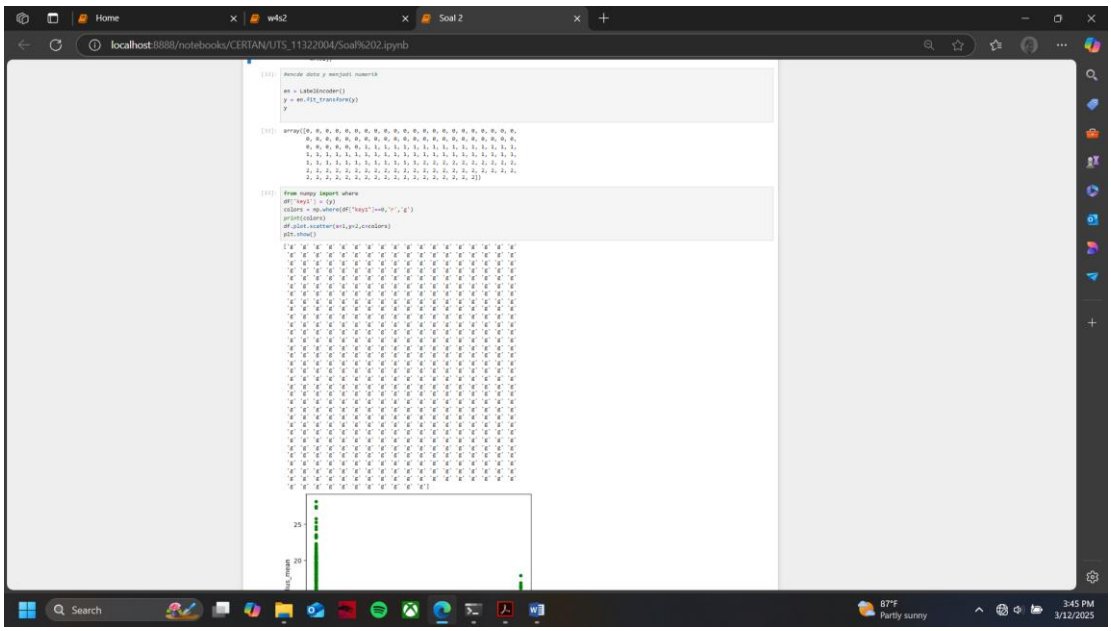

Home
w4s2
Soal 2
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%202.ipynb
jupyter Soal 2 Last Checkpoint: 1 hour ago
NIM : 11322004
Nama : Destina Manurung
Prodi : D3 Teknologi Informasi 2022
a. Klasifikasi menggunakan K-NN dan Naïve Bayes
Search
87°F
Partly sunny
3:44 PM
3/12/2025

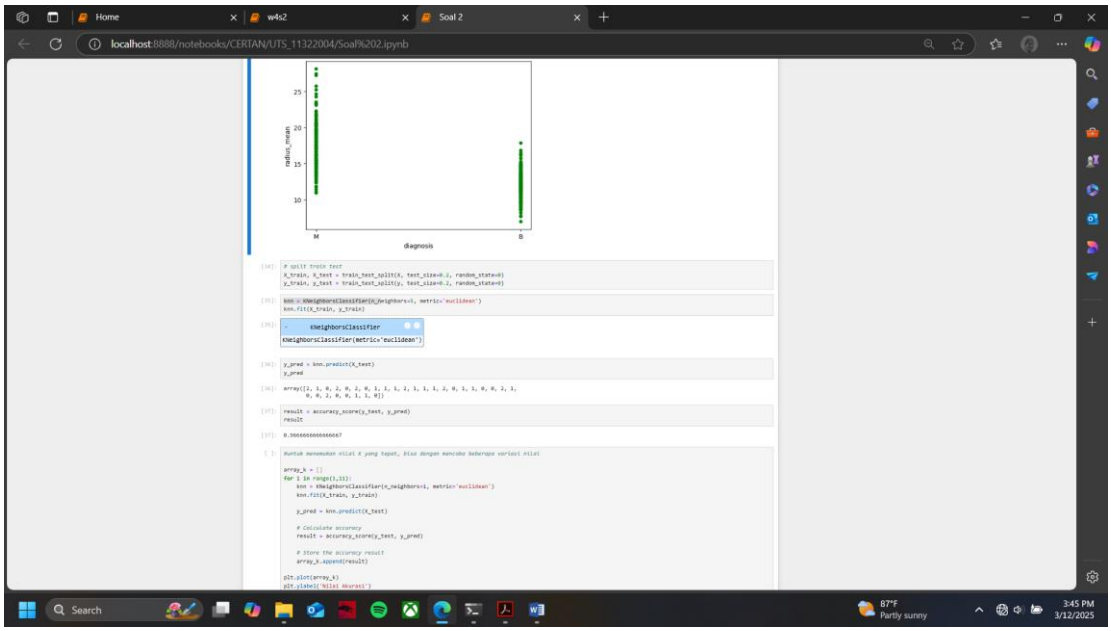

Home
w4s2
Soal 2
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%202.ipynb
Parallel Coordinates Plot for Iris Dataset
setosa
versicolor
virginica
sepal length (cm)
sepal width (cm)
petal length (cm)
petal width (cm)
Feature
Value
Search
87°F
Partly sunny
3:44 PM
3/12/2025

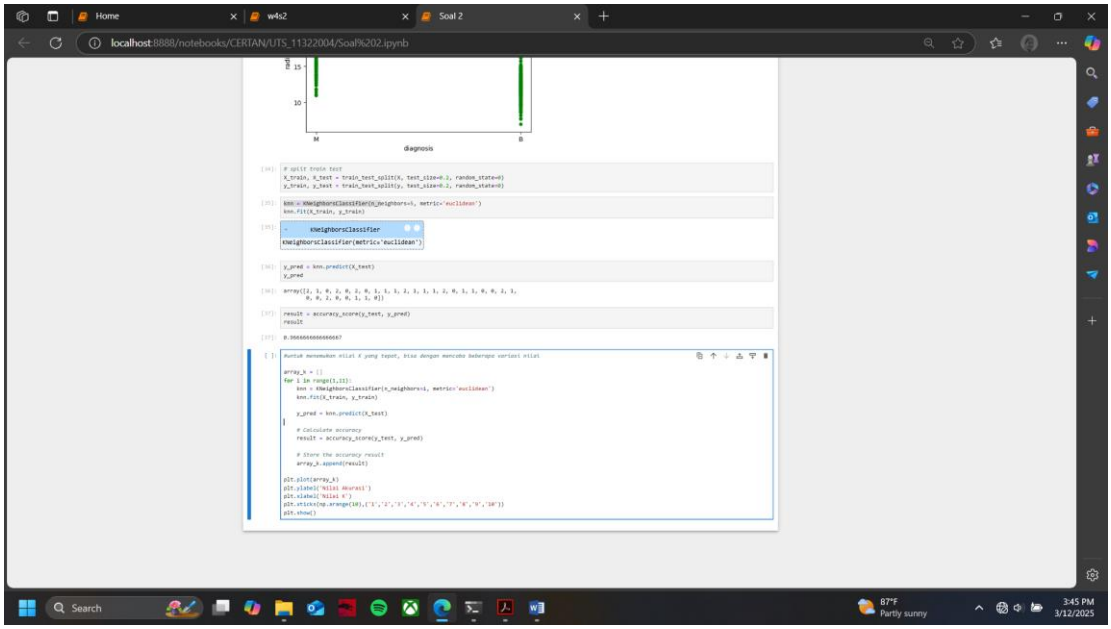

Home
w4s2
Soal 2
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%202.ipynb
KNeighborsClassifier
KNeighborsClassifier(metric='euclidean', n_neighbors=3)
Search
87°F
Partly sunny
3:45 PM
3/12/2025


Home
w4s2
Soal 2
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%202.ipynb
Search
87°F
Partly sunny
3:45 PM
3/12/2025


Home
w4s2
Soal 2
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%202.ipynb
Search
87°F
Partly sunny
3:45 PM
3/12/2025


Home
w4s2
Soal 2
localhost:8888/notebooks/CERTAN/UTS_11322004/Soal%202.ipynb
[32]: #encode data y menjadi numerik
le = LabelEncoder()
y = le.fit_transform(y)
y
[33]: from numpy import where
df['key1'] = (y)
colors = np.where(df["key1"]==0,'r','g')
print(colors)
df.plot.scatter(x=1,y=2,c=colors)
plot.show()
Search
87°F
Partly sunny
3:45 PM
3/12/2025



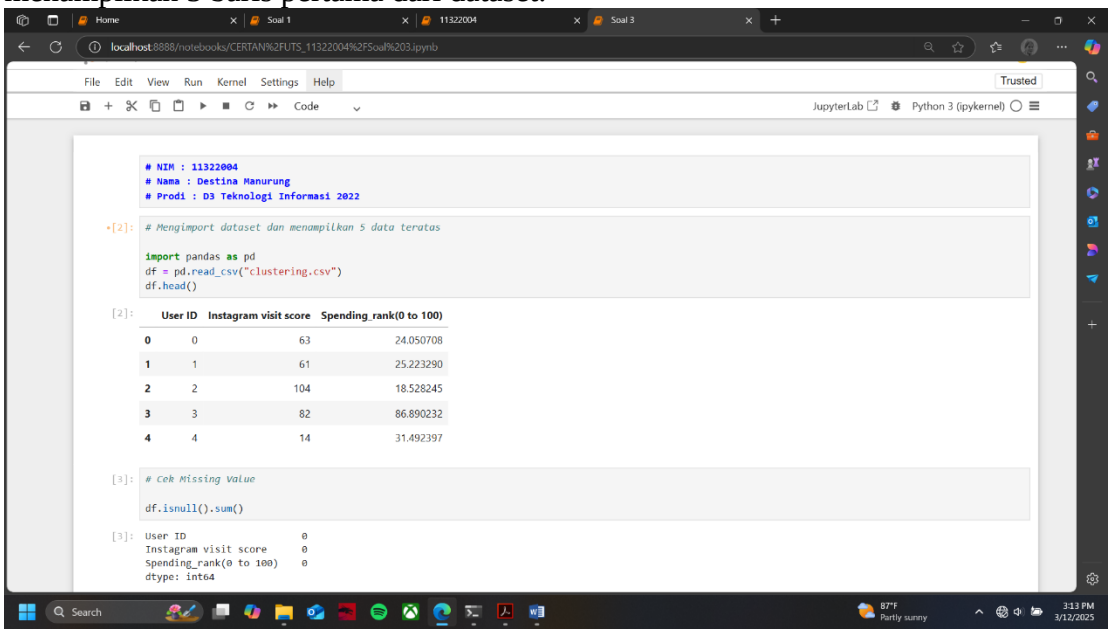


Soal 3

Dari *dataset 'clustering*.csv', tentukan nilai K optimal dan klasterisasi data dengan menggunakan algoritma K-Means.

Mengimpor library pandas untuk memanipulasi data, kemudia datasetnya dibaca dan

menampilkan 5 baris pertama dari dataset.



```
# NIM : 11322004
# Nama : Destina Manurung
# Prodi : D3 Teknologi Informasi 2022
```

```
# Mengimport dataset dan menampilkan 5 data teratas

import pandas as pd
df = pd.read_csv("clustering.csv")
df.head()
```

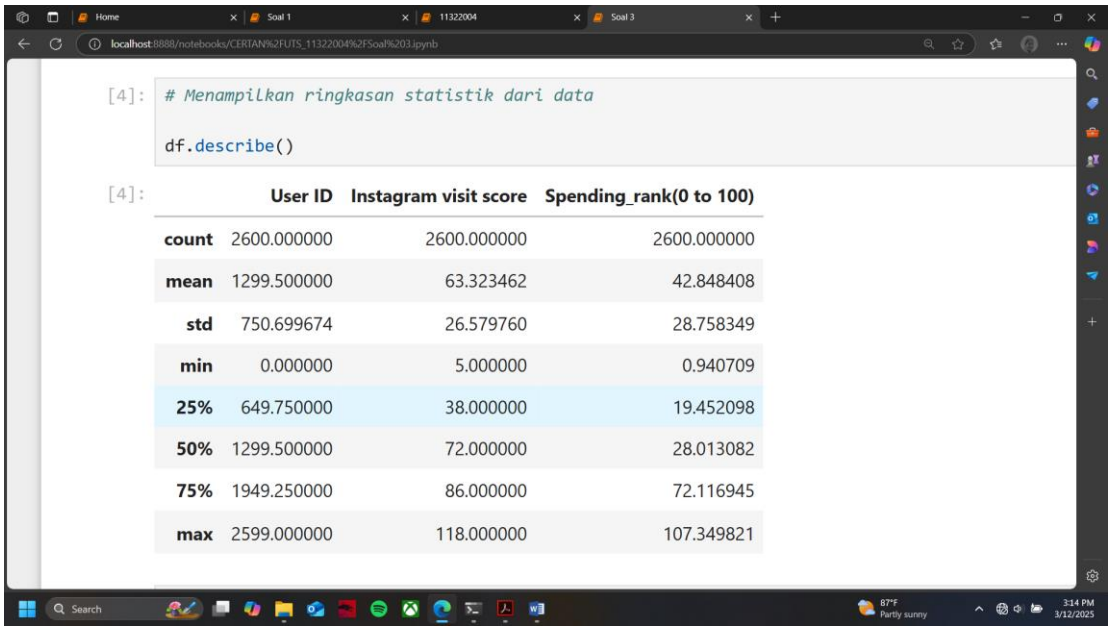
	User ID	Instagram visit score	Spending_rank(0 to 100)
0	0	63	24.050708
1	1	61	25.223290
2	2	104	18.528245
3	3	82	86.890232
4	4	14	31.492397

```
# Cek Missing Value

df.isnull().sum()
```

```
User ID                   0
Instagram visit score     0
Spending_rank(0 to 100)   0
dtype: int64
```

Mengecek nilai yang hilang (missing value) dalam setiap sel dataset kemudian menghitung jumlah nilai yang hilang di setiap kolom.

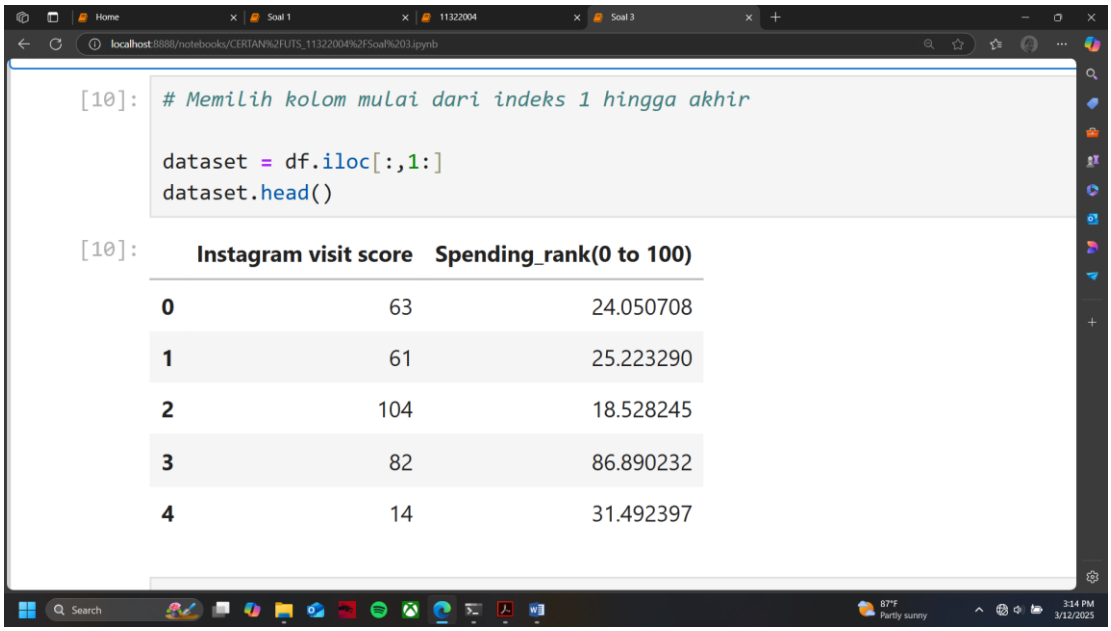


```
# Menampilkan ringkasan statistik dari data

df.describe()
```

	User ID	Instagram visit score	Spending_rank(0 to 100)
count	2600.000000	2600.000000	2600.000000
mean	1299.500000	63.323462	42.848408
std	750.699674	26.579760	28.758349
min	0.000000	5.000000	0.940709
25%	649.750000	38.000000	19.452098
50%	1299.500000	72.000000	28.013082
75%	1949.250000	86.000000	72.116945
max	2599.000000	118.000000	107.349821

Menampilkan ringkasan statistik dari data numerik dataset pelanggan seperti count, mean, std, min, 25% (Q1), 50% (median/Q2), 75% (Q3), dan max.



```
[10]: # Memilih kolom mulai dari indeks 1 hingga akhir

dataset = df.iloc[:,1:]
dataset.head()
```

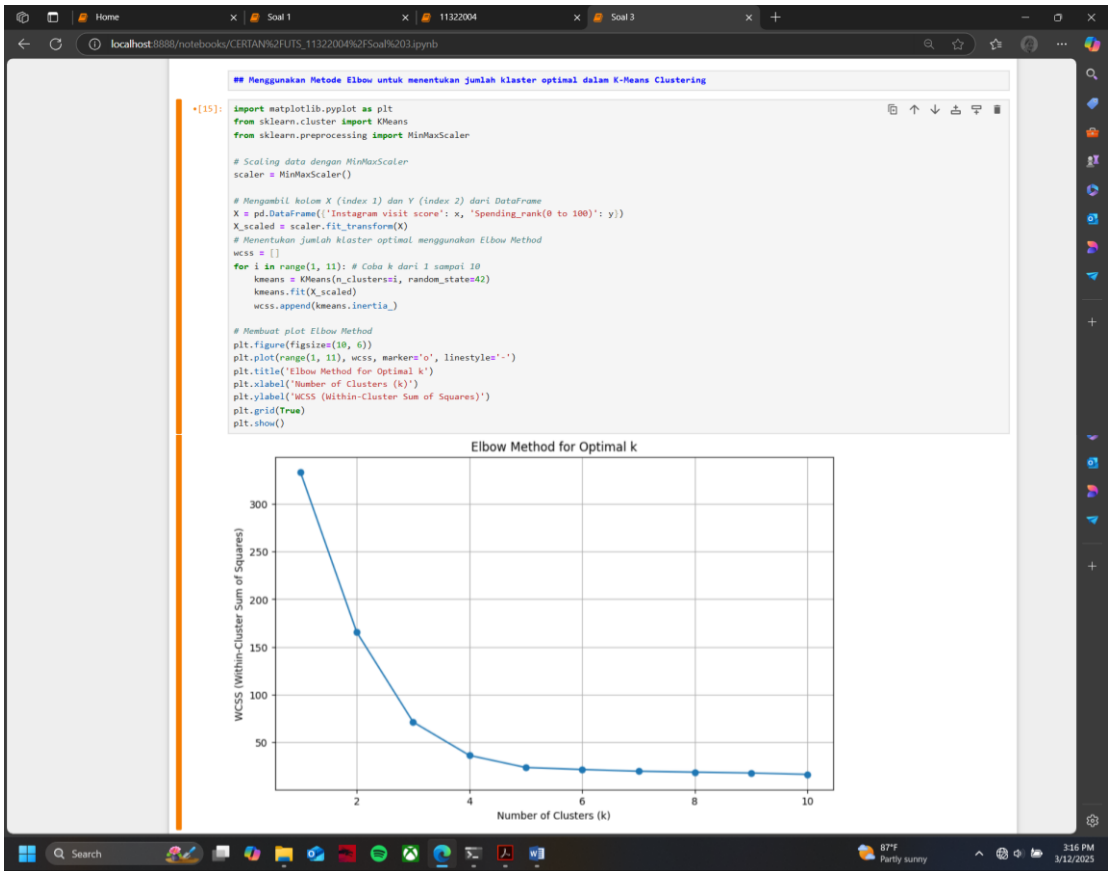
[10]:

	Instagram visit score	Spending_rank(0 to 100)
0	63	24.050708
1	61	25.223290
2	104	18.528245
3	82	86.890232
4	14	31.492397

Memilih kolom mulai dari indeks 1 hingga akhir. Hasilnya disimpan dalam variabel dataset dan ditampilkan dengan dataset.head(), yang menunjukkan 5 baris pertama.



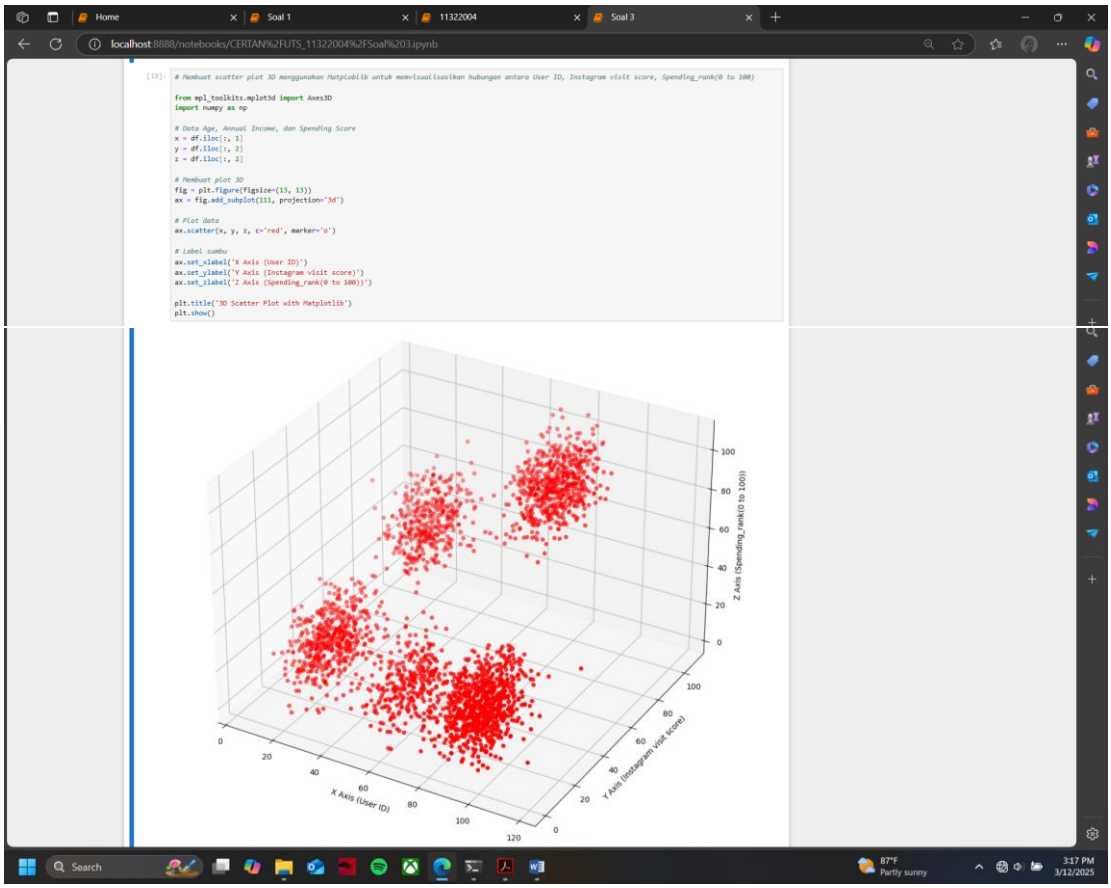
Membuat scatter plot menggunakan matplotlib untuk memvisualisasikan hubungan antara Annual Income (k$) (x = df.iloc[:, 3]) dan Spending Score (1-100) (y = df.iloc[:,4]). Scatter plot ini membantu mengidentifikasi pola atau klaster dalam data. Dari plot yang dihasilkan, terlihat bahwa data membentuk beberapa kelompok, yang bisa menjadi indikasi bahwa metode clustering seperti K-Means bisa diterapkan untuk analisis lebih lanjut.



Menggunakan Metode Elbow untuk menentukan jumlah klaster optimal dalam Kmeans Clustering dengan data ‘Instagram visit score' dan 'Spending_rank(0 to 100)’**.** Data dinormalisasi menggunakan MinMaxScaler, lalu algoritma K-Means dijalankan dengan jumlah klaster dari 1 hingga 10 untuk menghitung WCSS (Within-Cluster Sum of Squares)**.** Grafik Elbow menunjukkan hubungan antara jumlah klaster dan WCSS, di mana titik siku (elbow point) menandakan jumlah klaster optimal, kemungkinan k = 5, karena setelah itu penurunan WCSS melambat.



Menerapkan K-Means Clustering dengan k=5, yang sebelumnya ditentukan menggunakan Elbow Method. Model Kmeans(n_clusters=5) dilatih dengan data, lalu hasil klasterisasi divisualisasikan dengan menggunakan scattetr plot dengan warna berbeda untuk setiap klaster. Grafik mennunjukkan distribusi data berdasarkan ‘Instagram visit score' dan 'Spending_rank(0 to 100)’, dengan lima kelompok pelanggan yang memiliki karakteristik serupa dalam pengeluaran dan pendapatan.



Membuat scatter plot 3D menggunakan Matploblib untuk memvisualisasikan hubungan antara User ID, Instagram visit score, Spending_rank(0 to 100). Data dipetakan ke dalam ruang 3 dimensi dengan
sumbu X untuk Age, sumbu Y untuk Annual Income, dan sumbu Z untuk Spending Score yang membantu dalam memahami pola distribusi data dan potensi klaterisasi dalam 3 dimensi.